

VERJETNOST IN STATISTIKA



1 SLUČAJNI VEKTORJI

DEFINICIJA

Naj bo (Ω, \mathcal{F}, P) verjetnostni prostor. Preslikavi $X: \Omega \rightarrow \mathbb{R}$ recemo **SLUČAJNA SPREMEMBLJIVKA** (ss), če so vse množice $\{X \leq x\} = \{w; X(w) \in (-\infty, x]\} = X^{-1}((-\infty, x])$ dogodki. [\mathcal{F} je tu σ -algebra]

ZOLED

Kako bi na ta način formalirali met kovance?

Intuitivno: $X=1$ je vrzemo cifra

$X=0$ je vrzemo grb

$$\Omega = \{\text{prostori dopustnih metov}\} . X(\text{met}) = \begin{cases} 1 & ; \text{ cifra} \\ 0 & ; \text{ grb} \end{cases}$$

Če je X ss., lanko definiramo **KOMULATIVNO PORAZDELITVENO FUNKCIJO** (K.P.F.) $F_X: \mathbb{R} \rightarrow [0, 1]$ s predpisom

$$F_X(x) = P(X \leq x) = P(X^{-1}((-\infty, x]))$$

DEFINICIJA

Preslikava $X = (X_1, X_2, \dots, X_n): \Omega \rightarrow \mathbb{R}^n$ je **SLUČAJNI VEKTOR** (sv), če so $\{X_1 \leq x_1, \dots, X_n \leq x_n\} = X^{-1}((-\infty, x_1]) \times \dots \times X^{-1}((-\infty, x_n])$ dogodki za vse realne n-terice $(x_1, \dots, x_n) \in \mathbb{R}^n$

K.P.F. sv X je $F_X: \mathbb{R}^n \rightarrow [0, 1]$, definirana s predpisom $F_X(x_1, \dots, x_n) = P(X_1 \leq x_1, \dots, X_n \leq x_n)$

LASTNOSTI K.P.F.

(1) LIMITA $v -\infty$

$$\lim_{x_n \rightarrow -\infty} F(x_1, \dots, x_n, x_n) = \lim_{x_n \rightarrow -\infty} P(X_1 \in (-\infty, x_1] \times \dots \times (-\infty, x_{n-1}] \times (-\infty, x_n]) = \lim_{k \rightarrow \infty} P(X_1 \in k \times (-\infty, -k]) = \\ = P\left(\bigcap_{k \in \mathbb{N}} \{X_1 \leq x_1, \dots, X_n \leq x_n, X_n \leq -k\}\right) = P\left(\bigcap_{k \in \mathbb{N}} \{X \in k \times (-\infty, -k]\}\right) = P(\emptyset) = 0$$

Enako velja: $\lim_{x_n \rightarrow -\infty} F(x_1, \dots, x_n) = 0$ za vsi x_1, \dots, x_{n-1}

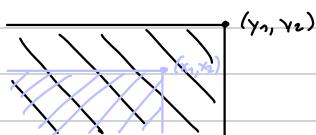
zveznost od spodaj

LIMITA $v \infty$

$$\lim_{(x_1, \dots, x_n) \rightarrow (\infty, \infty, \dots, \infty)} F(x_1, \dots, x_n) = P\left(\bigcup_{k \in \mathbb{N}} \{x_1 \leq k, x_2 \leq k, \dots, x_n \leq k\}\right) = P(X \in \mathbb{R}^n) = P(\Omega) = 1$$

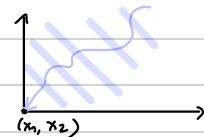
zveznost od spodaj

(2) MONOTONOST: Če $x_i \leq y_i$ za vse i , potem $F_X(x_1, \dots, x_n) \leq F_X(y_1, \dots, y_n)$. Ker je $(-\infty, x_1] \times \dots \times (-\infty, x_n) \subset (-\infty, y_1] \times \dots \times (-\infty, y_n)$ je $P(\dots) \leq P(\dots)$ zaradi monotonosti verjetnosti



(3) ZVEZNOST Z DESNE: če $(y_1, \dots, y_n) \downarrow (x_1, \dots, x_n)$ velja $F_X(x_1, \dots, x_n) \downarrow F_Y(y_1, \dots, y_n)$

$$\lim_{y_i \downarrow x_i} F_X(y_1, \dots, y_n) = F_X(x_1, \dots, x_n)$$

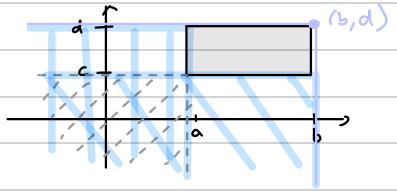


OPOMBA: Lastnosti (1), (2), (3) karakterizijo abstraktne k.p.f. v primeru $n=1$, torej v primeru S.S.

(4) Oglejmo si je lastnosti za sv. Vzemo n=2. Oglejmo si primer $(x, y) : \Omega \rightarrow \mathbb{R}^2$

$$P((x, y) \in (a, b] \times (c, d]) = F_x(b, d) - F_x(a, d) - F_x(b, c) + F_x(a, c) \geq 0$$

$$\text{za } a < b, c < d$$

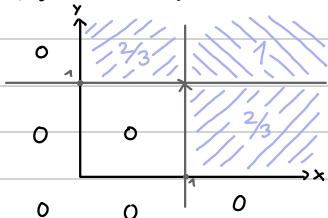


OPOMBA: Lastnosti (1), (2), (3), (4) karakterizirajo k.p.f. dvorazsežnega SV

Očitna poslošitev velja tudi za $n \geq 3$ (kvadri)

↳ ZGLED

Oglejmo si funkcijo $F: \mathbb{R}^2 \rightarrow [0, 1]$



Dokazali smo da 1, 2, 3 niso dovolj za karakterizacijo $1 - \frac{2}{3} - \frac{2}{3} + 0 \neq 0$

Icer je $\{X_1 \leq x_1, \dots, X_m \leq x_m\} = \bigcup_{k=1}^m \{X_1 \leq x_1, \dots, X_m \leq x_m, X_k \leq k\}$,

so posledično (X_1, \dots, X_m) podvektorji SV in tudi SV.

↳ DEFINICIJA

Vsi PODVEKTORJI SV (X_1, \dots, X_n) so slučajni vektorji.

Npr. $(X_1, \dots, X_{n-1}) : \{X_1 \leq x_1, \dots, X_{n-1} \leq x_{n-1}\} = \bigcup_{k=1}^{\infty} \{X_1 \leq x_1, \dots, X_{n-1} \leq x_{n-1}, X_n \leq k\}$ (*)

Posebej, če je (X_1, \dots, X_n) SV, so X_i SS (obrtna implikacija je očitna). Iz (*) je tudi razvidno

$$F(x_1, \dots, x_{n-1})^{(x_1, \dots, x_{n-1})} = \lim_{x_n \rightarrow \infty} F(x_1, \dots, x_n)^{(x_1, \dots, x_n)}$$

↳ POSLEDICA

(X_1, \dots, X_n) je SV natanko tedaj, ko so njegovi komplementi SS.

? SHADY

↳ ZGLED

$$P(X \in [110, 120] \text{ in } Y \in [80, 90]) \implies B = [110, 120] \times [80, 90]$$

$$P(X \geq 6 \text{ in } Y=0) = P(X \geq 6) \cdot P(Y=0) \implies B = [6, \infty) \times \{0\}$$

↳ OPOMBA

i) $\{X \in (-\infty, b]\}$ dogodek $\implies \{X \in (b, \infty)\}$ dogodek

ii) $\{X \in (a, b]\}$ dogodek

iii) Iz $[a, b] = \bigcap_{n=1}^{\infty} (a - \frac{1}{n}, b]$ sledi $\{X \in [a, b]\}$ je dogodek. Posebej $\{X = a\}$ je dogodek

iv) Iz $(a, b) = \bigcap_{n=1}^{\infty} (a, b - \frac{1}{n}]$ je $\{X \in (a, b)\}$ dogodek

Če je $X: \Omega \rightarrow \mathbb{R}^n$ slučajni vektor, so množice $\{X \in B\}$ dogodki za vse Borelove množice B.

↳ LANSKA OPOMBA → lepsi napisano

Naj bo $X: \Omega \rightarrow \mathbb{R}$ SS. Potem velja:

$$\begin{aligned}\rightarrow \{X \in (a, b]\} &= \{X \in (-\infty, b]\} \cap \{X \in (-\infty, a]\}^c \\ \rightarrow \{X \in (a, b)\} &= \bigcup_{c_n > b} \{X \in [a, c_n]\} \\ \rightarrow \{X \in [a, b]\} &= \bigcap_{n=1}^{\infty} \{X \in (a - \frac{1}{n}, b + \frac{1}{n})\} \\ \rightarrow \{X = x\} &\end{aligned}$$

Zgoraj lahko "kombiniramo" (števne unije, presekti, komplementi; ŠTEVNO). Izkaže se, da obstajajo verjetnosti $P(X \in B)$, kjer je B poljubna "Borelova" množica $\subset \mathbb{R}$.

↳ BORELOVE MNOŽICE

• Borelove množice $\subset \mathbb{R}$

$$\begin{aligned}\rightarrow \text{vsi intervali} \\ \rightarrow \text{vse elementarne množice}\end{aligned}\quad \left[\begin{aligned}+ \text{števne unije} \\ + \text{števni presekti}\end{aligned}\right]$$

• Borelove množice $\subset \mathbb{R}^2$

$$\begin{aligned}\rightarrow \text{vsi krogi} \\ \rightarrow \text{vse elementarne množice} \\ \rightarrow \text{vse metrično odprte množice} \\ \rightarrow \text{vse zaprte množice}\end{aligned}\quad \left[\begin{aligned}+ \text{števne unije} \\ + \text{števni presekti}\end{aligned}\right]$$

• Borelove množice $\subset \mathbb{R}^n$

$$\rightarrow \text{podobno kot v } \mathbb{R}^2 \text{ in posplošeno}$$

ZVEZNI SLUČAJNI VEKTORJI

DEFINICIJA

Slučajni vektor $X: \Omega \rightarrow \mathbb{R}^n$ ima „zvezno“ gostoto $f_X: \mathbb{R}^n \rightarrow [0, \infty)$, če za vsako Borelove množico $B \subset \mathbb{R}^n$ velja

$$P(X \in B) = \int_B f_X(x) dx, \quad \text{kjer si lahko mislimo, da gre za izlimitirani Riemannov integral.}$$

$\hookrightarrow x = (x_1, \dots, x_n)$
 $dx = dx_1 \times \dots \times dx_n$

Funkcija $f: \mathbb{R}^n \rightarrow \mathbb{R}$ je „zvezna“, če je množica točk neveznosti zanemarljiva za n -termi integral.

ZGLED

$$X \sim U(a, b), \quad \text{če ima } X \text{ gostoto } f_X(u) = \frac{1}{b-a} \mathbf{1}_{(a,b)}(u). \quad \text{Lahko bi uzel} \quad f_X(u) = \begin{cases} \frac{1}{b-a} \cdot \mathbf{1}_{[a,b]}(u) & ; u \neq \frac{a+b}{2} \\ 0 & ; u = \frac{a+b}{2} \end{cases}$$

Osebdotimo se na dvorazsežne slučajne vektorje $(X, Y): \Omega \rightarrow \mathbb{R}^2$ z „zvezno“ gostoto. Tedaj je

$$F_{(X,Y)}(x,y) = P((X,Y) \in (-\infty, x] \times (-\infty, y]) = \int_{(-\infty, x] \times (-\infty, y]} f_{(X,Y)}(u,v) du dv = \int_{-\infty}^x \left(\int_{-\infty}^y f_{(X,Y)}(u,v) dv \right) du = \int_{-\infty}^x \left(\int_{-\infty}^y f_{(X,Y)}(u,v) du \right) dv$$

Za martingalni/robni k.p.f. vredna $F_X(u) = \lim_{y \rightarrow \infty} F_{(X,Y)}(u,y) = \int_{-\infty}^u \left(\int_{-\infty}^y f_{(X,Y)}(u,v) dv \right) du = \int_{-\infty}^u \left(\int_{-\infty}^{\infty} f_{(X,Y)}(u,v) dv \right) du \quad [\text{in podobno za } F_Y]$

Od tod sledi $f_X(u) = F'_X(u) = \int f_{(X,Y)}(u,v) dv$ za skoraj vse u (*)

osnovni izrek analize

$$\text{Podobno } f_Y(v) = F'_Y(v) = \int f_{(X,Y)}(u,v) du \quad (\text{**})$$

(formalnije: če je $f_{(X,Y)}: \mathbb{R}^2 \rightarrow [0, \infty)$ gostota vektorja (X, Y) sta z izrazoma (*) (**) definirani (možni) marginalni gostoti)

Naјpomembnejša dvorazsežna zvezna porazdelitev je **DVORAZSEŽNA NORMALNA PORAZDELITEV**

DEF: Naј bosta μ_X, μ_Y realni števili in $\Sigma = \begin{bmatrix} \sigma_x^2 & \sigma_{XY} \\ \sigma_{XY} & \sigma_y^2 \end{bmatrix}$ (simetrična) pozitivno definitna matrika, kjer je σ_{XY} realno število.

[Op: Σ je pd $\Leftrightarrow \sigma_x^2 \sigma_y^2 - \sigma_{XY}^2 > 0$. Pravimo, da je S.V. (X, Y) porazdeljen normalno po zakonu $N \left(\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \begin{bmatrix} \sigma_x^2 & \sigma_{XY} \\ \sigma_{XY} & \sigma_y^2 \end{bmatrix} \right)$, če ima

gostoto $f_{(X,Y)}(x,y) = \frac{1}{2\pi\sqrt{\det\Sigma}} e^{-\frac{1}{2}\left(\frac{(x-\mu_X)^2}{\sigma_x^2} + \frac{(y-\mu_Y)^2}{\sigma_y^2}\right)}$

$$= \frac{1}{2\pi\sqrt{\det\Sigma}} e^{-\frac{1}{2}\frac{1}{\sigma_x^2\sigma_y^2 - \sigma_{XY}^2} ((\mu_X - x)^2 + 2\sigma_{XY}(x - \mu_X)(y - \mu_Y) + (\mu_Y - y)^2)}$$

Vpeljemo $\rho = \frac{\sigma_{XY}}{\sigma_X \cdot \sigma_Y} = \frac{\sigma_{XY}}{\sqrt{\sigma_X^2 \cdot \sigma_Y^2}}$. Vidimo, da lahko σ_{XY} (kot parameter) nadomestimo z parametrom $\rho \in [-1, 1]$.

$$\Sigma^{-1} = \frac{1}{\det\Sigma} \begin{bmatrix} \sigma_y^2 & -\sigma_{XY} \\ -\sigma_{XY} & \sigma_x^2 \end{bmatrix}$$

$$\text{Gostoto } f_{(X,Y)} \text{ lahko izrazimo kot: } f_{(X,Y)}(x,y) = \frac{1}{2\pi\sigma_X\sigma_Y\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)} \left(\left(\frac{x-\mu_X}{\sigma_X} \right)^2 + 2\rho \left(\frac{x-\mu_X}{\sigma_X} \right) \left(\frac{y-\mu_Y}{\sigma_Y} \right) + \left(\frac{y-\mu_Y}{\sigma_Y} \right)^2 \right)}$$

$$= \frac{1}{2\pi\sigma_X\sigma_Y\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)} \left\langle \begin{bmatrix} 1-\rho \\ 1 \end{bmatrix}, \begin{bmatrix} \frac{x-\mu_X}{\sigma_X} \\ \frac{y-\mu_Y}{\sigma_Y} \end{bmatrix} \right\rangle}$$

ta kvadratna forma je konstanta

Niugnice funkcije so elipse → glej lanski zvezek

Izkazuje se, da velja $\mu_X = E(X)$, $\mu_Y = E(Y)$, $\sigma_X^2 = \text{Var}(X)$, $\sigma_Y^2 = \text{Var}(Y)$, $\sigma_{XY} = \text{Cov}(X, Y)$

Posplošimo: S.V. $X: \Omega \rightarrow \mathbb{R}^n$ je porazdeljen po zakonu $N(\mu, \Sigma)$, kjer je $\mu \in \mathbb{R}^n$ in $\Sigma \in \mathbb{R}^{n \times n}$ s.p.d., če ima n-razsežno gostoto

$$f_X(u) = (2\pi)^{-\frac{n}{2}} (\det\Sigma)^{-\frac{1}{2}} e^{-\frac{1}{2}\left\langle u-\mu, \Sigma^{-1}(u-\mu) \right\rangle}$$

2 NEODVISNOST SLUČAJNIH SPREMENLJIVK

DEFINICIJA - NEODVISNOST

Komponente vektorja (X_1, \dots, X_n) so neodvisne, če velja $F_{(X_1, \dots, X_n)}^{(x_1, \dots, x_n)} = F_{X_1}^{(x_1)} \cdot F_{X_2}^{(x_2)} \cdot \dots \cdot F_{X_n}^{(x_n)}$ za vse realne n-torce x_1, \dots, x_n .

Zgoraj enakost lahko prepisemo v: $P(X_1 \in (-\infty, x_1]) \cap \dots \cap X_n \in (-\infty, x_n]) = P(X_1 \in (-\infty, x_1]) \cdot \dots \cdot P(X_n \in (-\infty, x_n])$

Izkazuje se, da so s.s. X_1, \dots, X_n neodvisne \iff

$$P\left(\bigcap_{i=1}^n (X_i \in B_i)\right) = \prod_{i=1}^n P(X_i \in B_i)$$

za vse n-torce Borelovih množic $B_1, \dots, B_n \subset \mathbb{R}$

↳ Posebej s.s. X in Y sta neodvisni, če velja $P(X \in A \text{ in } Y \in B) = P(X \in A) \cdot P(Y \in B)$ za vse Borelove pere $A, B \subset \mathbb{R}$.

↳ Če so X_1, \dots, X_n neodvisne, sta vsaki X_i, X_j ($i \neq j$) neodvisni, obratno pa ne velja (kot pri neodvisnosti n-torce dogodkov)

TRDITEV

Naj ima slučajni vektor (X, Y) gostoto $f_{(X, Y)}$. Tedaj sta X in Y neodvisni $\iff f_{(X, Y)}^{(x, y)} = f_X(x) \cdot f_Y(y)$

za skoraj vse realne $(x, y) \in \mathbb{R}^2$

↳ To dodamo, saj je za tiste podmnožice, ki imajo mero 0, jih integral na katerega je verzna gostota, "ne vidi"

$$\text{DOKAZ } (\Rightarrow): \text{Vemo } \int_{-\infty}^y \int_{-\infty}^x f_{(X, Y)}^{(u, v)} du dv = \int_{-\infty}^y f_X(u) du \cdot \int_{-\infty}^y f_Y(v) dv \quad \text{za } X, Y$$

$$\text{Odvajamo po } X: \int_{-\infty}^y f_{(X, Y)}^{(x, v)} dv = f_X(x) \cdot \int_{-\infty}^y f_Y(v) dv \quad (\text{kjer sta leva in desna stran odvedljivi})$$

uporabimo osnovni izrek analize

$$\text{Odvajamo po } Y \text{ in ustrezni rezultat sledi: } [f_{(X, Y)}^{(x, y)} = f_X(x) \cdot f_Y(y) \quad \forall]$$

$$(\Leftarrow) \text{ Privzamemo } f_{(X, Y)}^{(u, v)} = f_X(u) \cdot f_Y(v) \text{ za skoraj vse pere } (u, v) \in \mathbb{R}^2$$

$$\text{Sledi } \int_{(-\infty, u] \times (-\infty, v]} f_{(X, Y)}^{(u, v)} du dv = \int_{(-\infty, u] \times (-\infty, v]} f_X(u) \cdot f_Y(v) du dv$$

\downarrow
Lahko bi vzel $A \times B$ za
kateri koli Borelov množici
 A in B

(Fubinijev izrek daje dvojni integral enak "kvadratnik")

$$\text{kar po Fubinijevu izreku pomenu ravno } F_{(X, Y)}^{(u, v)} = F_X(u) \cdot F_Y(v)$$

↳ ZGLED: Nuj; bo $(X, Y) \sim N\left(\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \begin{bmatrix} \sigma_X^2 & \sigma_{XY} \\ \sigma_{YX} & \sigma_Y^2 \end{bmatrix}\right)$. Izkaj, sta X, Y neodvisni?

$$f_{(X, Y)}^{(x, y)} = \frac{1}{2\pi} \frac{1}{\sqrt{\sigma_X \sigma_Y}} e^{-\frac{1}{2(\sigma_X^2 + \sigma_Y^2)} \left(\left(\frac{x-\mu_X}{\sigma_X}\right)^2 + 2\rho \left(\frac{x-\mu_X}{\sigma_X}\right) \left(\frac{y-\mu_Y}{\sigma_Y}\right) + \left(\frac{y-\mu_Y}{\sigma_Y}\right)^2 \right)}$$

na obeh straneh so gostote gladke

$$f_X(x) = \frac{1}{\sqrt{2\pi}} \frac{1}{\sigma_X} e^{-\frac{1}{2} \left(\frac{x-\mu_X}{\sigma_X}\right)^2}$$

$$f_Y(y) = \frac{1}{\sqrt{2\pi}} \frac{1}{\sigma_Y} e^{-\frac{1}{2} \left(\frac{y-\mu_Y}{\sigma_Y}\right)^2}$$

KAKO SMO IZRAČUNALI ZGORAJI INTEGRALI, DA SMO DOBILI ROBNE PORAZDELITVE

po X , da dobri $f_X(u)$ · ignorirali bi konstante na začetku

$$\cdot \int e^{-(ax^2+bx)}$$

· nova sprememba

· dobili gama funkcijo...

• Če velja $f_{(x,y)}(x,y) = f_x(x) \cdot f_y(y)$ za skoraj vse parje x,y v tem primeru (glede na enakost) sledi enakost za vse parje x,y
 Pri $(x,y) = (\mu_x, \mu_y)$ dobimo enakost $\frac{1}{2\pi} \cdot \frac{1}{\sigma_x \sigma_y \sqrt{2\pi}} = \frac{1}{\sigma_x \sqrt{2\pi}} \cdot \frac{1}{\sigma_y \sqrt{2\pi}}$
 od tod sledi $f=0 \iff f_{x,y}=0$

• Če je $P=0$, je ocitno $f_{(x,y)}(x,y) = f_x(x) f_y(y)$ povsod

Vidimo: komponenti dvorazsežnega normalnega velikosti sta neodvisni \iff nekorelirani

↪ PODOBNO. Če je (x_1, \dots, x_n) n-ravščino normalno porazdeljen, so X_1, X_2, \dots, X_n neodvisne $\iff x_1, \dots, x_n$ so paroma nekorelirane $\iff X_1, \dots, X_n$ so paroma neodvisne
 ↓
 neodvisno \iff nekoreliranje
 samo ko so porazdeljene normalno, drugače ni \iff

4 POSLEDICA TRDITVE

Naj ima (X,Y) gostoto $f_{(X,Y)}$. Tedaj sta X in Y neodvisni $\iff f_{(X,Y)}(x,y) = \phi(x) \cdot \psi(y)$ za skoraj vse x in y za neki integrabilni funkciji ϕ in ψ .

IDEJA DOKAŽA: za neki $a > 0$ je $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \phi(x) \psi(y) dx dy = \int_{-\infty}^{\infty} \frac{1}{a} \psi(y) dy = 1$. Sledi, da sta $\frac{1}{a} \psi$ in $a \phi$ različici gostot f_X in f_Y .

3 TRANSFORMACIJE SLUČAJNIH SPREMENLJIVK IN VEKTORJEV

• MOTIVACIJA: Če poznamo porazdelitev s.v. X in je g primerna funkcija kar je lahko "izrazimo" porazdelitev transformacije $g(X)$

• V DISKRETNEM PRIMERU je to preprosto: če je X diskreten s.v. z vrednostmi $\{x_i \mid i \in I\}$ in je g "kateralni" funkcija, je $g(x)$ slučajni vektor (ali S.S.) z vrednostmi $\{y_j \mid j \in J\}$ za kjer: $y_j = g(x_i)$
Ocitno je $P(g(x_i) = y_j) = \sum_x 1_{\{y_j = g(x)\}} \cdot P(x = x_i)$

$$\text{ZGLED: } X \sim \begin{pmatrix} -1 & 0 & 1 \\ \frac{1}{3} & \frac{1}{2} & \frac{1}{6} \end{pmatrix} \Rightarrow X^2 \sim \begin{pmatrix} 1 & 0 & 1 \\ \frac{1}{3} & \frac{1}{2} & \frac{1}{6} \end{pmatrix} = \begin{pmatrix} 0 & 1 \\ \frac{1}{2} & \frac{1}{2} \end{pmatrix}$$

TRANSFORMACIJA SS. $X: \Omega \rightarrow (a, b)$

• Privzamemo, da je X "zvezna" S.S., za katere je $P(X \in (a, b)) = 1$ in ne bi bo $g: (a, b) \rightarrow (c, d)$ odredujiva bijekcija.

Zanima nas porazdelitev transformacije $g(x)$ [odtovr → zveznost (njeno mor biti zvezna)]

OPOMBA: dopuščamo tudi neomejene intervale

• Privzamemo, da je g strogo naraščajoča. Nuj bo $z \in \mathbb{R}$.

↓
bijekcija mora biti monotone,
torej je lahko samo strogo
naraščajoča ali strogo padajoča

$$\text{Racunamo } F_{g(X)}(z) = P(g(X) \leq z) = \begin{cases} P(X \leq g^{-1}(z)) & ; z \in (c, d) \\ \quad \wedge \quad & ; z \geq d \\ 0 & ; z \leq c \end{cases}$$

če ima X gostoto f_X , sledi:

$$f_{g(X)}(z) = F'_{g(X)}(z) = \begin{cases} f_X(g^{-1}(z)) \cdot (g'(z))' & ; z \in (c, d) = \mathbb{1}_{(c, d)}(z) \cdot \frac{f_X(g^{-1}(z))}{g'(g^{-1}(z))} \\ 0 & ; \text{sicer} \end{cases}$$

OP: Formula sledi iz verižnega pravila!

Za DN "izračunaj" $F_{g(X)}(z)$ v primera podajoče funkcije g .

↓
paži, kaj se zgodi v ujemku

• V primera gostote za odredujivo bijekcijo g v splošnem velja

$$f_{g(X)}(z) = \mathbb{1}_{(c, d)}(z) \cdot \frac{f_X(g^{-1}(z))}{|g'(g^{-1}(z))|}$$

TRANSFORMACIJSKA FORMULA

OP: absolutno vrednost moramo dodati, saj je v primera podajoči g odvod negativen, kar pa neličilo uredu, saj mora biti gostota vedno pozitivna

• ZGLED

$$X \sim N(0, 1) \Rightarrow f_X(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}}$$

Nuj bo $a \neq 0, b \in \mathbb{R}$ in $g(x) = ax + b$ (linearna bijekcija)

Po transformacijski formula je

$$f_{ax+b}(z) = \frac{1}{\sqrt{2\pi}} e^{-(\frac{z-b}{a})^2/2} \cdot \frac{1}{|a|}$$

Prepoznamo gostoto porazdelitve $N(b, a^2)$

↳ ZGLED: Nemonotone transformacije

Zanimo na " $N(0,1)^2$ " oziromo X^2 , če je $X \sim N(0,1)$

[Tu je "problem", saj kvadratna funkcija ni injektivna] \rightarrow

OP: Ideja teorema zgleda:

Tač v primeru da nismo imeli injektivne g, lahko domnožimo razdelimo na injektivne dele in potem računamo naprej

Izračunajmo kar kpf.: V zemino $z \geq 0$, $\forall z \in \mathbb{R} \geq 0$ itak verjetnost \circ

$$F_Z(z) = P(X^2 \leq z) = P(|X| \leq \sqrt{z}) = P(-\sqrt{z} \leq X \leq \sqrt{z}) \stackrel{\text{zveznost}}{=} P(X \leq \sqrt{z}) - P(X \leq -\sqrt{z}) = F_X(\sqrt{z}) - F_X(-\sqrt{z})$$

↳ sledi $f_{X^2}(z) = [F'_{X^2}(z) = (F_X(\sqrt{z}) - F_X(-\sqrt{z}))'] = f_X(\sqrt{z}) \cdot \frac{1}{2\sqrt{z}} + f_X(-\sqrt{z}) \cdot \frac{1}{2\sqrt{z}}$

V primeru $X \sim N(0,1)$ dobimo $f_{X^2}(z) = \frac{1}{\sqrt{z}} \cdot \frac{1}{\sqrt{2\pi}} e^{-\frac{z}{2}}$

To je gostota porazdelitve X^2 (ni-kvadrat z eno prostorsk stropnjo) oziromo $\Gamma(\frac{1}{2}, \frac{1}{2})$

↳ KOMENTAR: V literaturi uporabljajo $N(\mu, \sigma^2)$ ali $N(\mu, \Sigma)$. Meniča miktje ne uporablja $N(\mu, \sqrt{\Sigma})$ za učrasseno normalno. Mi bomo uporabljali kar $N(\mu, \Sigma)$

TRANSFORMACIJE SLUČAJNIH VEKTORJEV

↳ TRDITEV: Nuj so X s.v. z urednimi v \mathbb{R}^n in njih v $h: \mathbb{R}^n \rightarrow \mathbb{R}$ zvezna funkcija. Tedaj je $h(x)$ slučajna spremenljivka

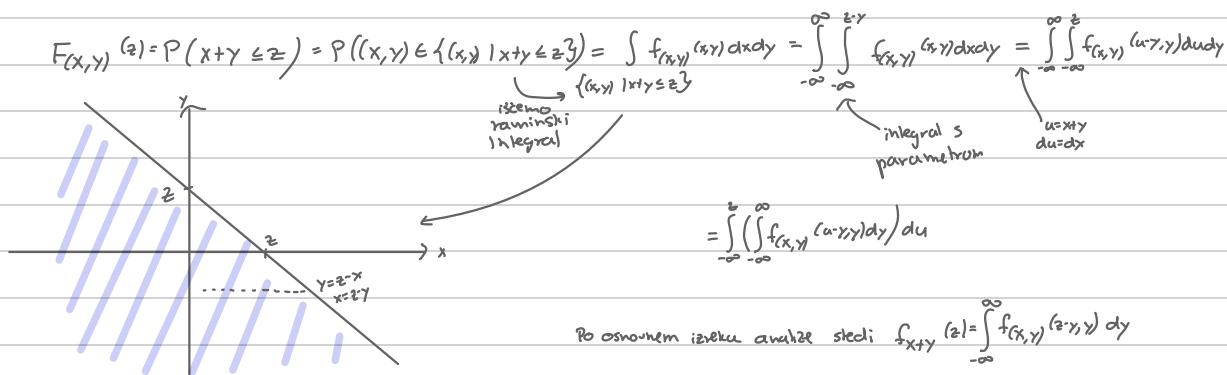
DOKAZ: $\{h(x) \leq z\} = \{h(x) \in (-\infty, z]\} = \{x \in h^{-1}((-\infty, z])\}$
 ↓ pravilka zaprtca

Pravilka zaprtke množice je zagotovljena, torej Borelava, torej gre za dogodek

↳ ZGLED: Obračunajmo vprasanje porazdelitve vsole $X+Y$, tuje $h: \mathbb{R}^2 \rightarrow \mathbb{R}$

$$h(x, y) = x+y$$

Pričakujemo tveda, da ima (x, y) gostoto $f_{(x,y)}$



če sta X in Y neodvisni, se gostota f_{x+y} poenostavi v $f_{x+y} = \int_{-\infty}^{\infty} f_x(z-y) f_y(y) dy$

Tej konstrukciji (kako iz dveh gostot naredimo "tretjo") recemo Ikonvolucija GOSTOT f_x in f_y

↳ V splošnem porazdelitev funkciji $h(x_1, \dots, x_n)$ najenostavujejo "izracunamo" tako, da $h: \mathbb{R}^n \rightarrow \mathbb{R}$ dopolnimo do diferencibilne

bijekcijo $g: D \rightarrow E$ med odprtima podmnožicama D in E prostora \mathbb{R}^n

$$\text{Torej: } g(x_1, \dots, x_n) = (\underline{h(x_1, \dots, x_n)}, g_2(x_1, \dots, x_n), \dots, g_n(x_1, \dots, x_n))$$

↳ dan je bijekcija

Tedaj je $h(x_1, \dots, x_n)$ marginalna robna porazdelitev porazdelitve $g(x_1, \dots, x_n)$

↳ ZGLED: $h(x, y) = x + y$ lahko dopolnimo do $g(x, y) = (x + y, y)$

↳ TRDITEV: Naj bo $f_X: \mathbb{R}^n \rightarrow [0, \infty)$ gostota "zveznega" vektorja X , za katerega je $P(X \in D) = 1$ in naj bo $g: D \rightarrow E$ diferencibilna bijekcija med odprtima množicama D in $E \subseteq \mathbb{R}^n$. Tedaj ima transformacija $g(x)$ gostoto

$$f_{g(X)}(z) = f_X(g^{-1}(z)) |\det Jg^{-1}(z)| \cdot \mathbf{1}_E(z) = \mathbf{1}_E(z) \cdot \frac{f_X(g^{-1}(z))}{|\det Jg^{-1}(z)|}$$

OP: Ponovi Jacobija iz analize

DOKAZ: Naj bo C Borelova ($= E$). $P(g(X) = C) = P(\underline{g^{-1}(C)})$

$$\stackrel{\substack{\text{pravilna} \\ \text{Borelove} \\ \text{množice}}}{\int_{g^{-1}(C)} f_X(x) dx} = \int_C f_X(g^{-1}(z)) \cdot |\det Jg^{-1}(z)| dz$$

↓ izrek o zamenjavi
 spremenjivk ↓
 $z = g(x)$
 $x = g^{-1}(z)$

(zamenjava
spremenjivk v
n-tistem integralu)

[7.3]

↳ Pogledimo si tradicionalen zapis za dvorazsežnih S.V.:

Standardno pišemo $g(x, y) = (u, v)$ oziroma $u = u(x, y)$, $v = v(x, y)$, ter $(x, y) = g^{-1}(u, v)$ oziroma $x = X(u, v)$, $y = Y(u, v)$

Transformacijska formula se glasi:

$$f_{(u,v)}(u, v) = f_{(x,y)}(x(u,v), y(u,v)) \left| \begin{array}{c|c} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial v} \\ \hline \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v} \end{array} \right|_{(x(u,v), y(u,v))} \det \left| \begin{array}{c|c} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial v} \\ \hline \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v} \end{array} \right|_{(x(u,v), y(u,v))}$$

abs
poz, po katerih sprem. računamo

$$f_{(u,v)}(u, v) = \frac{f_{(x,y)}(x(u,v), y(u,v))}{\left| \begin{array}{c|c} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial v} \\ \hline \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v} \end{array} \right|_{(x(u,v), y(u,v))}}$$

↳ ZGLED

① Izračunajmo gostoto vsote $x+y$ za "zvezen" S.V. (x, y) :

Funkcijo $U = x+y$ dopolnimo do diferencibilne bijekcije $\mathbb{R}^2 \rightarrow \mathbb{R}^2$ s funkcijo $V = y$ ($g(x, y) = (x+y, y)$)

Inverz je podan z $x = U-V$, $y = V$. Sledi:

$$f_{(x+y, y)}(u, v) = \frac{f_{(x,y)}(u-v, v)}{\left| \begin{array}{c|c} 1 & 1 \\ \hline 0 & 1 \end{array} \right|} = f_{(x,y)}(u-v, v)$$

Gostota S.S. $U = x+y$ je robna gostota, torej $f_{(x+y, y)}(u) = \int_{-\infty}^{\infty} f_{(x,y)}(u-v, v) dv$

② Izračunajmo se gustoča produkta $U=X \cdot Y$

Funkciju U dopolimo do diferencijabilne bijekcije $\overbrace{\mathbb{R}^n \setminus \{0\}}^D \rightarrow \overbrace{\mathbb{R}^n \setminus \{0\}}^E$ s funkcijom $V=Y$. Inverz je podan sa $X=\frac{U}{V}$, $Y=V$

Stedi $f_{(X,Y)}(u,v) = \frac{f_{(X,Y)}(\frac{u}{v}, v)}{\left| \begin{pmatrix} u & v \\ 0 & 1 \end{pmatrix} \right|} = \frac{1}{|V|} \cdot f_{(X,Y)}\left(\frac{u}{v}, v\right)$ za $v \neq 0$

in $f_{XY}(u) = \int_{-\infty}^{\infty} \frac{1}{|V|} f_{(X,Y)}\left(\frac{u}{v}, v\right) dv$

simetrična, pozitivno
definitna

↳ TRDITVEV

Naj bo $X \sim N(\mu, \Sigma)$, kjer je $\mu \in \mathbb{R}^n$ in $\Sigma \in \mathbb{R}^{n \times n}$ s.p.d., in naj bosta $A \in \mathbb{R}^{n \times n}$ obrnjiva matrika ter $v \in \mathbb{R}^n$ poljuben vektor. Tedaj velja $A \cdot X + v \sim N(A\mu + v, A\Sigma A^T)$

Saj je pričakovana
vrednost linearan
operator

Var je kvadratičen operator,
nemovemo dati $A^T \Sigma$, saj potem
var ni s.p.d.

$\boxed{\text{Var}(ax+bx) = a^2 \cdot \text{Var}(x)}$

↳ varianca je kvadratičen operator, ki ne prepozna konstant

DOKAZ

Gre za transformacijo $g: \mathbb{R}^n \rightarrow \mathbb{R}^n$, $g(x) = Ax + v$

↳ ker je A tudi obrnjiva in je funkcija linearna, bo tudi funkcija obrnjiva, torej imamo inverz

Inverz: $g^{-1}(z) = A^{-1}(z-v)$

Seveda je $Jg(x) = A$

$Jg(x): \mathbb{R}^n \rightarrow \mathbb{R}^n$ bomo interpretirali kot preslikavo

[odtvoj funkcij je tista funkcija,
ki jo v točki najboljjje približuje]

$$\begin{aligned} \text{Po transformacijski formalni je } f_{Ax+v}(x) &= \frac{f_X(A^{-1}(z-v))}{|\det A|} \\ &= (2\pi)^{-\frac{n}{2}} \cdot (\det \Sigma)^{-\frac{1}{2}} \cdot \frac{1}{|\det A|} e^{-\frac{1}{2} \langle \Sigma^{-1}(A^{-1}(z-v)-\mu), A^{-1}(z-v)-\mu \rangle} \\ &\stackrel{\text{množenje}}{=} (2\pi)^{-\frac{n}{2}} \cdot (\det \Sigma)^{-\frac{1}{2}} \cdot \frac{1}{\sqrt{|\det A|^2}} e^{-\frac{1}{2} \langle \Sigma^{-1}(A^{-1}(z-v)-\mu), A^{-1}(z-v)-\mu \rangle} \\ &= (2\pi)^{-\frac{n}{2}} \cdot (\det \Sigma)^{-\frac{1}{2}} \cdot \frac{1}{\sqrt{|\det(A\Sigma A^T)|}} e^{-\frac{1}{2} \langle \Sigma^{-1}(A^{-1}(z-v)-\mu), A^{-1}(z-v)-\mu \rangle} \\ &= (2\pi)^{-\frac{n}{2}} \cdot \det(A\Sigma A^T)^{-\frac{1}{2}} e^{-\frac{1}{2} \langle (A\Sigma A^T)^{-1}(z-(A\mu+v)), z-(A\mu+v) \rangle} \end{aligned}$$

4 PRICAKOVANA VREDNOST SLUČAJNIH SPREMENLJIVK IN VETORJEV

DEFINICIJA

Naj bo X "zvezna" s.s. z gostoto $f_X: \mathbb{R} \rightarrow [0, \infty)$. Pricakovana vrednost s.s. X je

$$E(X) = \int_{-\infty}^{\infty} x \cdot f_X(x) dx, \text{ če obstaja } (\Leftrightarrow \int_{-\infty}^{\infty} |x| \cdot f_X(x) dx < \infty)$$

Za S.V. (X_1, \dots, X_n) definiramo $E((X_1, \dots, X_n)) = (E(X_1), \dots, E(X_n))$

KOMENTAR: Smisel ima tudi definicija $E(X) = \int_{\mathbb{R}^n} x \cdot f_X(x) dx$ za S.V. X z gostoto $f_X: \mathbb{R}^n \rightarrow [0, \infty)$.

$$\text{Res: } \int_{\mathbb{R}^n} x_i \cdot f_X(x_1, \dots, x_n) dx_1 \dots dx_n = \int_{\mathbb{R}^{n-1}} x_i \left(\int_{\mathbb{R}} f_X(x_1, \dots, x_n) dx_1 \dots dx_{n-1} \right) dx_n = \int_{x_i=-\infty}^{\infty} x_i \cdot f_{X_i}(x_i) dx_i = E(X_i)$$

Podobno definiramo prisakovano vrednost slučajnih matrik

ZGLED

- Če je $X \sim \text{Cauchy}(0, 1)$, $E(X)$ ne obstaja. Pisemo: $E(\text{Cauchy}(0, 1))$ ne obstaja
- $E(U(a, b)) = \frac{a+b}{2}$
- $E(N(\mu, \sigma^2)) = \mu$

TRDITEV

Naj bo $g: \mathbb{R} \rightarrow \mathbb{R}$ zvezna (ali $g: (a, b) \rightarrow \mathbb{R}$ zvezna, ki jo razširimo ≥ 0 zunaj (a, b)) in naj bo X "zvezna" s.s. z gostoto f_X . Tedaj je:

$$E(g(X)) = \int_{-\infty}^{\infty} g(x) \cdot f_X(x) dx, \text{ če obstaja.}$$

DOKAZ: Za primer, ko je $P(X \in (a, b)) = 1$ in je $g: (a, b) \rightarrow (c, d)$ odvečljiva bijekcija. Tedaj vemo, da ima $g(x)$ gostoto:

$$f_{g(x)}(z) = f_X(g^{-1}(z)) \cdot |(g^{-1})'(z)| \cdot \mathbf{1}_{(c, d)}(z)$$

Zato $E(g(x)) = \int_c^d f_X(g^{-1}(z)) \cdot \left| \frac{d}{dz} (g^{-1}(z)) \right| dz = \int_a^b g(x) \cdot f_X(x) dx$

$z = g(x)$

Zaradi urejenih mej imamo
abs. ???

ZGLED

Posebej izračimo $E(|X|)$ za "zvezno" s.s. z gostoto f_X . Najprej $F_{|X|}(z) = P(|X| \leq z) = \mathbf{1}_{(0, \infty)}(z) \cdot P(X \in [-z, z]) = \mathbf{1}_{(0, \infty)}(z) \cdot (F_X(z) - F_X(-z))$

Slede: $f_{|X|}(z) = \mathbf{1}_{(0, \infty)}(z) \cdot (f_X(z) + f_X(-z))$ in zato

$$E(|X|) = \int_0^{\infty} z \cdot (f_X(z) + f_X(-z)) dz = \int_{-\infty}^{\infty} |z| \cdot f_X(z) dz$$

POSLEDICA (ZGLEDA IN TRDITVE)

Za "zvezno" s.s. X z gostoto f_X velja $E(|X|^p) = \int_{-\infty}^{\infty} |x|^p f_X(x) dx$

$$E(|X|^p) = \int_{-\infty}^{\infty} z^p (f_X(z) + f_X(-z)) dz = \int_{-\infty}^{\infty} |z|^p f_X(z) dz \rightarrow \text{obrazložitev z uporabo zgornjega zgleda}$$

↳ TRDITEV

Naj bo $h: \mathbb{R}^n \rightarrow \mathbb{R}$ "zvezna" (Borelova) in naj bo X "zvezen" s.v. z gostoto $f_X: \mathbb{R}^n \rightarrow [0, \infty)$. Tedaj velja

$$E(h(x)) = \int_{\mathbb{R}^n} h(x) \cdot f_X(x) dx \quad \text{če obstaja}$$

↳ ZGLED

Naj bo (x, y) "zvezen" s.v. z gostoto $f_{(x,y)}$; izračunajmo $E(x+y)$. Vemo, da velja

$$f_{x+y}(w) = \int_{-\infty}^{\infty} f_{(x,y)}(u-v, v) du$$

$$\text{Po definiciji je zato } E(x+y) = \int_{-\infty}^{\infty} u \cdot f_{x+y}(u) du = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} u \cdot f_{(x,y)}(u-v, v) dv du = \int_{\mathbb{R}^2} \dots du dv = \int_{\mathbb{R}^2} (x+y) f_{(x,y)}(x+y) dx dy$$

↑ \uparrow
uvredimo
 $u=x+y$
 $v=y$

Nadaljujemo račun: $= \int_{-\infty}^{\infty} x \int_{-\infty}^{\infty} f_{(x,y)}(x,y) dx dy + \int_{-\infty}^{\infty} y \int_{-\infty}^{\infty} f_{(x,y)}(x,y) dx dy = E(x) + E(y)$

↳ POSLEDICA TRDITVE

$$E(x \cdot y) = \int_{\mathbb{R}^2} x \cdot y \cdot f_{(x,y)}(x,y) dx dy, \text{ če obstaja}$$

DN: če sta X in Y neodvisni in obstajata $E(x)$ in $E(y)$, obstajajo tudi: $E(xy) = E(x) \cdot E(y)$

↳ DOKAZ TRDITVE

Za primer ko je $P((x,y) \in D) = 1$ in je $h|_D$ mogoče dopolniti do diferencirabilne bijekcije

$$g = (h, k): D \rightarrow E$$

Tedaj ima $h(x,y)$ (koč robna para zadelelju vektorja $g(x,y)$) gostoto

$$f_{h(x,y)}(u) = \int_{-\infty}^{\infty} f_{(x,y)}(g^{-1}(u,v)) \cdot |\det J g^{-1}(u,v)| \cdot \mathbf{1}_E(u,v) du$$

$$\text{Zato je } E(h(x,y)) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} u \cdot f_{(x,y)}(g^{-1}(u,v)) \cdot |\det J g^{-1}(u,v)| \mathbf{1}_E(u,v) du dv = \int_D h(x,y) f_{(x,y)}(x,y) dx dy = \int_{\mathbb{R}^2} h(x,y) f_{(x,y)}(x,y) dx dy$$

↳ POSLEDICA ADITIVNOSTI PRIČAKOVANE VREDNOSTI

Če je $X \leq Y$ n.g., je $E(X) \leq E(Y)$ (Tu $X \leq Y$ sg. pomeni $P((\omega | X(\omega) \leq Y(\omega)) = 1)$)

Iz $X \leq Y$ namreč sledi: $Y = X + (Y - X)$, kjer je $Y - X \geq 0$ sg.

↳ TRDITEV

Naj bo X in Y s.s., za kateri obstajata $E(x^2)$ in $E(y^2)$. Tedaj obstajata tudi: $E(xy)$ in velja: $|E(xy)| \leq \sqrt{E(x^2)} E(y^2)$

t.i. CAUCHY-SCHWARZOVNA NEENAKOST

DOKAZ: Iz $(u-v)^2 \geq 0$ sledi: $uv \leq \frac{1}{2}(u^2+v^2) \dots$ kot pri VERJETNOSTI 1 → glej lanski VIS

DODATEK: Velja $E(x \cdot y) = \sqrt{E(x^2) \cdot E(y^2)} \iff \frac{y}{\sqrt{E(y^2)}} = \frac{x}{\sqrt{E(x^2)}}$ n.g.

in $E(x \cdot y) = -\sqrt{E(x^2) \cdot E(y^2)} \iff \frac{y}{\sqrt{E(y^2)}} = -\frac{x}{\sqrt{E(x^2)}} \quad$ n.g.

Pripomnimo, da iz trditve sledi sklep $E(x^2) < \infty \Rightarrow E(|x|) < \infty$ (in $E(|x|) \leq \sqrt{E(x^2)}$)

DISPERZIJA, KOVARIANCA, VARIANČNO-KOVARIANČNA Matrika

DEFINICIJA

Disperzija (varianca) s.s. X je

$$D(x) = \text{Var}(x) = E((x - E(x))^2)$$

če obstaja. Vidimo, da obstajati pričakovana vrednost, da lahko obravnavamo obstoj variance

Gre za pričakovano kvadratično odstopanje s.s. X od njene pričakovane vrednosti. To je mera "razpršenosti" s.s. X .

$\exists (x - E(x))^2 = x^2 - 2E(x)x + E(x)^2$ sledi da že obstaja $E(x^2)$ obstaja tudi varianca in velja

$$D(x) = E(x^2) - E(x)^2$$

"to ni def, ampak bolj "postedica"

Dalje definiramo STANDARDNI ODKLON s.s. X kot

$$\sigma = \sigma(x) = \sqrt{D(x)} ; \text{ pišemo tudi } D(x) = \sigma(x)^2$$

če ima X enote, imata $\sigma(x)$ enake enote, torej je $\sigma(x)$ "neposredno" primerljiv z X .

"inspiracija iz prve norme"

OPOMBa: Morda bi bila pričakovana vrednost $E(|X-E(x)|)$ intuitivnejša (in lažje razložljiva) mera za odstopanje, vendar je

iz teoretičnega zornega kota kvadratično odstopanje mnogo preprostejše

OP: Inspiracija sledi druge norme, ki imajo povezano s skalarnim produktom

ZGLED

$$\begin{aligned} & X \sim U\left(\frac{1}{3}, \frac{2}{3}\right). \text{ Vemo, da je } E(x)=0, \text{ zato je } D(x)=E(x^2)=\int_{\frac{1}{3}}^{\frac{2}{3}} x^2 dx = \frac{x^3}{3} \Big|_{\frac{1}{3}}^{\frac{2}{3}} = \frac{\frac{8}{27}}{3} + \frac{\frac{1}{27}}{3} = \frac{2}{24} = \frac{1}{12} \\ & X \sim N(0,1). E(x)=0 \implies D(x)=E(x^2)=\int_{-\infty}^{\infty} x^2 \cdot \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx = \sqrt{\frac{2}{\pi}} \int_0^{\infty} \sqrt{2u} e^{-u} du = \sqrt{\frac{2}{\pi}} \int_0^{\infty} u^{\frac{1}{2}} e^{-u} du = \sqrt{\frac{2}{\pi}} \Gamma\left(\frac{3}{2}\right) = \sqrt{\frac{2}{\pi}} \cdot \frac{1}{2} \cdot \Gamma\left(\frac{1}{2}\right) = 1 \end{aligned}$$

LASTNOSTI DISPERZIJE

$D(x) \geq 0$ in $D(x)=0 \iff X = \text{konst. s.g.} \iff X = E(x) \text{ s.g.}$

$D(x)$ je minimum funkcije $a \mapsto E((x-a)^2)$

$$\text{Res: } E((x-a)^2) = E((x-E(x)) + (E(x)-a)^2) = D(x) + (E(x)-a)^2$$

$D(aX+b) = a^2 D(x)$ [pravimo, da je disperzija kvadraten operator]

$D(x+y) = D(x) + D(y)$ če sta X in Y neodvisni

$$\text{Res: } (x+y - E(x)-E(y))^2 = (x - E(x))^2 + 2(x - E(x))(y - E(y)) + (y - E(y))^2 \text{ in če sta } X \text{ in } Y \text{ neodvisni, je } E((x-E(x))(y-E(y)))=0$$

$$D(x) = \int_{-\infty}^{\infty} (x - E(x))^2 f_x(x) dx \text{ za "zvezno" s.s. } X \text{ z gostoto } f_x$$

DEFINICIJA

KOVARIANCA s.s. X in Y je pričakovana vrednost

$$K(x,y) = \text{Cov}(x,y) = E((x-E(x)) \cdot (y-E(y))), \text{ če obstaja}$$

Očitno morata "njegovi" obstajati $E(x)$ in $E(y)$

OP: Kovarianca meri jakost linearne povezanosti med s.s. X in Y .

OP: Meri korrelacijo oz. odvisnost med X in Y

če znamo $(x - E(x))(y - E(y))$ sledi $K(x,y) = E(x \cdot y) - E(x) \cdot E(y)$

(natančneje: če obstajajo $E(x), E(y)$ in $E(xy)$ obstaja tudi $K(x,y)$ in velja zgornja formula)

LASTNOSTI KOVARIANCE

- če obstajata $E(x)$ in $E(y)$, obstaja tudi $K(x,y)$ in velja $|K(x,y)| \leq \sqrt{D(x) \cdot D(y)} = \sigma(x) \cdot \sigma(y)$. To je Cauchy-Schwarzova neenakost

(izpeljava: uporabimo Cauchy-Schwarzova neenakost za $X-E(X)$ in $Y-E(Y)$)

$$\text{Dalej velja } K(x,y) = \sqrt{D(x) \cdot D(y)} \iff \frac{x-E(x)}{\sqrt{D(x)}} = \frac{y-E(y)}{\sqrt{D(y)}} \text{ A.g. [pravimo, da sta } X \text{ in } Y \text{ zg. "pozitivno" linearne povezani]}$$

$$K(x,y) = -\sqrt{D(x) \cdot D(y)} \iff -\frac{x-E(x)}{\sqrt{D(x)}} = \frac{y-E(y)}{\sqrt{D(y)}} \text{ A.g. [pravimo, da sta zg. "negativno" linearne povezani]}$$

- Kovarianca je simetričen bilinearen operator

$$K(a_1x_1 + a_2x_2, y) = a_1 K(x_1, y) + a_2 K(x_2, y)$$

linearnost v prvem faktorju

$$K(X, b_1Y_1 + b_2Y_2) = b_1 K(X, Y_1) + b_2 K(X, Y_2)$$

RES: simetričnost je odrita, zato je dovolj dokazati linearnost v enem faktorju:

$$K(a_1x_1 + a_2x_2, y) = E((a_1(x_1 - E(x_1)) + a_2(x_2 - E(x_2)))(y - E(y))) = a_1 K(x_1, y) + a_2 K(x_2, y)$$

$$K(x, x) = D(x)$$

$$K(x, y) = \int_{\mathbb{R}^2} (x - E(x))(y - E(y)) f(x, y) dx dy, \text{ če je } (x, y) \text{ "zvezen" s.v. z gostoto } f(x, y)$$

$$D(x+y) = D(x) + 2K(x, y) + D(y) \text{ za splošni SS. } X \text{ in } Y \in E(x^2) < \infty \text{ in } E(y^2) < \infty$$

glej lastnosti disperzije

$$\text{Splošno je: } D(x_1 + x_2 + \dots + x_n) = \sum_{i=1}^n \sum_{j=1}^n K(x_i, x_j) = \sum_{i=1}^n D(x_i) + 2 \sum_{i < j} K(x_i, x_j)$$

VARIANČNO-KOVARIANČNA MATRICA

DEFINICIJA

Variančno-kovariančna (variančna) matrika slučajne S.V. $X = (X_1, \dots, X_n)$ je matrika z elementi: $[\text{Var}(X)]_{ij} = K(X_i, X_j)$.

Vidimo, da je $\text{Var}(X)$ simetrična matrika z variančnimi komponenti po diagonali.

$$\text{Velja } \text{Var}(X) = E \left(\underbrace{(X - E(X))}_{\text{stolpec}} \underbrace{(X - E(X))^T}_{\text{vrstica}} \right)$$

Naj bo A poljubna matrika. Tedaj je $A \cdot A^T$ simetrična matrika, ki je vedno pozitivna $\langle A \cdot A^T x, x \rangle = \|A^T x\|^2 \geq 0$

Sledi $\text{Var}(X) \geq 0$

ZGLED

$$\text{Obravnavajmo } (X, Y) \sim N \left(\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \begin{bmatrix} \sigma_{XX}^2 & \sigma_{XY} \\ \sigma_{XY} & \sigma_{YY}^2 \end{bmatrix} \right)$$

$$\text{če je } A = \begin{bmatrix} 1 & b \\ 0 & 1 \end{bmatrix} \text{ (za neko realno število } b), \text{ je } A \cdot \begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix} = \begin{bmatrix} X + bY \\ Y \end{bmatrix} \sim N \left(\begin{bmatrix} \mu_X + b\mu_Y \\ \mu_Y \end{bmatrix}, A \cdot \begin{bmatrix} \sigma_{XX}^2 & \sigma_{XY} \\ \sigma_{XY} & \sigma_{YY}^2 \end{bmatrix} A^T \right)$$

$$\begin{bmatrix} \sigma_{XX}^2 + 2b\sigma_{XY} + b^2\sigma_{YY}^2 & \sigma_{XY} + b\sigma_{YY} \\ \sigma_{XY} + b\sigma_{YY} & \sigma_{YY}^2 \end{bmatrix}$$

$$\text{Vzemimo } b = -\frac{\sigma_{XY}}{\sigma_{YY}^2}; \text{ za ta } b \text{ dobimo matriko: } \begin{bmatrix} \sigma_{XX}^2 + 2b\sigma_{XY} + b^2\sigma_{YY}^2 & 0 \\ 0 & \sigma_{YY}^2 \end{bmatrix}$$

Vemo, da sta tedaj komponenti $X + bY$ in Y neodvisni. Iz faktorizacije gostot sledi $Y \sim N(\mu_Y, \sigma_{YY}^2)$

$$\text{Dalje iz neodvisnosti } X + bY \text{ in } Y \text{ sledi } 0 = K(X + bY, Y) = K(X, Y) + b K(Y, Y) = K(X, Y) + b \cdot \sigma_{YY}^2 = K(X, Y) - \frac{\sigma_{XY}}{\sigma_{YY}^2} \cdot \sigma_{YY}^2$$

Konečno sledi $\sigma_{XY} = K(X, Y)$

(zato da je simetrična sledi $X \sim N(\mu_X, \sigma_{XX}^2)$)

DODATEK: Vemo $a \cdot N(0, 1) + b \sim N(b, a^2)$

$$D(N(b, a^2)) = a^2 \cdot D(N(0, 1)) = a^2$$

izracunanji poviši gama funkcijo

Splošno za S.V. $X \sim N(\mu, \Sigma)$ velja $E(X) = \mu$ in $\text{Var}(X) = \Sigma$

DEFINICIJA: Pearsonov korelacijski koeficient s.s. X in Y je $\rho(X, Y) = \frac{K(X, Y)}{\sigma(X)\sigma(Y)}$. Vemo $\rho(X, Y) \in [-1, 1]$

Vemo: $\rho(X, Y) = 1 \iff X$ in Y sta s.g. pozitivno linearno povezani

$\rho(X, Y) = -1 \iff X$ in Y sta s.g. negativno linearno povezani

DEFINICIJA: S.S. X in Y sta nekorelirani $\iff \rho(X, Y) = 0$

Vemo, da sta X in Y nekorelirani, če sta neodvisni, obratno pa v splošnem ni res.

če pa sta X in Y komponenti dvorazsežnega normalnega vektora, velja tudi obratno.

5 POGOJNE PORAZDELITVE IN POGOJNA PRIČAKOVANA VREDNOST

5 PRIMER

Naj bo $X := \text{LDL}$ (holisterol „nizke“ gostote \rightarrow „stруpeni“)

in $Y := \text{SKT}$ (sistolični krvni tlak)

Želimo formalno podlagi za $P(Y \in [110, 130] | X=3)$

GLAVNI PROBLEM POGOJNE VERjetnosti: Mi smo "elementarno" pogojno verjetnost že definirali pri verjetnosti kot $P(Y \in B | X=x) = \frac{P(Y \in B \cap X=x)}{P(X=x)}$, vedar če je X zvezna SS bo $P(X=x)=0$, torej bi imeli 0 v ulomku, zato smo v naslednji definiciji upeljali limito.

↳ Uvodoma definiramo pogojne porazdelitve takole.

Naj bo B boreluva in naj bo x „verjetna“ vrednost SS X .

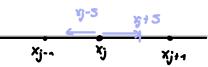
DEFINICIJA #1: Pogojna verjetnost, da SS X zavzame vrednost v B , pogojno na $X=x$, je $P(Y \in B | X=x) = \lim_{\delta \downarrow 0} P(Y \in B | X \in (x-\delta, x+\delta))$ če obstaja. Tu je x „verjetna“ vrednost, če je $P(X \in (x-\delta, x+\delta)) > 0$ za vsa $\delta > 0$.

Za „zvezno“ SS X je $P(X \in (x-\delta, x+\delta)) = \int_{x-\delta}^{x+\delta} f_X(u) du$, je to res npr.: če je f_X zvezna pri x in $f_X(x) > 0$

Ta def ni popolnoma matematično pravilna, zato pa jo bomo še malo dopolnili v nadaljevanju.

5 ZGLED

Naj bo X diskretna $\sim \begin{pmatrix} x_1 & x_2 & \dots & x_n \\ p_1 & p_2 & \dots & p_n \end{pmatrix}$ za $p_i > 0$ za vse j . Da si malo oljčimo lahko še učinkemo, da so x_i -i urejeni po vrsti



$P(Y \in B | X \in (x_j - \delta, x_j + \delta)) = P(X=x_j)$ za vse dovolj majhne $\delta > 0$ je $P(Y \in B | X \in (x_j - \delta, x_j + \delta)) = P(Y \in B | X=x_j)$ za vse dovolj majhne $\delta > 0$

→ Torej nam ta nova def v primeru diskretne SS. vrne elementarno pogojno, kar je resno kar smo želeli.

5 TRDITEV

Naj bo (X, Y) „zvezen“ S.V. z gostoto $f_{X,Y}(x,y)$ in naj bo B boreluva množica. Dalje naj bo f_X zvezna in pozitivna pri x . Torej velja

Tedaj velja $P(Y \in B | X=x) = \frac{1}{f_X(x)} \int_B f_{X,Y}(x,y) dy$ (pri določnih blagih predpostavkah)

$$\text{DOKAZ: } P(Y \in B | X \in (x-\delta, x+\delta)) = \frac{\int_{x-\delta}^{x+\delta} f_{X,Y}(u,y) du dy}{\int_{x-\delta}^{x+\delta} f_X(u) du} \rightarrow \text{OP: Dodali smo } \frac{1}{2\delta} \text{ zato da bomo lahko uporabili zakon o integralni stečnjki vrednosti (glej Analiza 2: posledica osnevnega zakona analize)}$$

$$\text{Imenovalec: } \frac{1}{2\delta} (F_X(x+\delta) - F_X(x-\delta)) \xrightarrow{\substack{\delta \downarrow 0 \\ \text{torej } F'_X \text{ kar je raven } f_X(x)}} f_X(x)$$

↓
to je F'_X kar je raven $f_X(x)$

↓
ostanek pa je enak

$$\text{Števec: } \frac{1}{2\delta} \int_{x-\delta}^{x+\delta} \left(\int_B f_{X,Y}(u,y) dy \right) du \xrightarrow{\substack{\delta \downarrow 0 \\ \text{torej moramo imeti pogoj}}} g(y)$$

↓
za omor iz zakona o integrali, mora biti g zvezna, torej moramo imeti pogoj

če je g zvezna pri x

• Zadnjic: iz uvodne definicije $P(Y \in B | X=x)$ smo izpeljali enakost $P(Y \in B | X=x) = \int_B \frac{f_{(x,y)}(y)}{f_X(x)} dy$ (pri pogojih f_X je zvezna in pozitivna v x in dodatnemu pogoju)

$$\text{ker je } \int_{\mathbb{R}} \frac{f_{(x,y)}(y)}{f_X(x)} dy = \frac{1}{f_X(x)} \cdot "f_X(x)" = 1$$

Smiselno je torej definirati pogojne gostote:

$$f_{(Y|X)}(y|x) = \begin{cases} \frac{f_{(x,y)}(y)}{f_X(x)} & ; \text{ če } f_X(x) > 0 \\ f_Y(y) & ; \text{ če } f_X(x) = 0 \end{cases}$$

funkcija spremenljivke y

• DROBNI TISK: začenemo pri $f_{(x,y)}$ in definiramo $f_X(x) := \int f_{(x,y)}(y) dy$ in $f_Y(y) := \int f_{(x,y)}(x) dx$. Če sta X in Y neodvisni, lahko izpeljemo $f_X(x) = f_X(x) \cdot f_Y(y)$

DEFINICIJA #2

Pogojna porazdelitev $P(Y \in \dots | X=x)$ je porazdelitev z gostoto $y \mapsto f_{(Y|X)}(y|x)$

Eksplicitno je $P(Y \in B | X=x) \stackrel{\text{(def)}}{=} \int_{\mathbb{R}} f_{(Y|X)}(y|x) dy$

TRDITEV

$$\text{Velja } P(Y \in B) = \int P(Y \in B | X=x) \cdot f_X(x) dx \quad [\text{zakon popolne verjetnosti}]$$

$$P(Y \in B) = \sum_i P(Y \in B | X=x_i) \cdot P(X=x_i)$$

$$\text{DOKAZ: } \int_{\mathbb{R}} P(Y \in B | X=x) f_X(x) dx = \int_{\substack{\{f_X(x) > 0\} \\ B}} \left(\int_{\mathbb{R}} \frac{f_{(x,y)}(y) dy}{f_X(x)} \right) f_X(x) dx = \int_{\mathbb{R} \times B} f_{(x,y)}(y) dy = P((x,y) \in \mathbb{R} \times B) = P(Y \in B)$$

DEFINICIJA

Pogojna pričakovana vrednost ss. y , pogojno na $X=x$, je $E(Y | X=x) = \int_{\mathbb{R}} y f_{(Y|X)}(y|x) dy$

Sledi $E(g(y) | X=x) = \int g(y) f_{(Y|X)}(y|x) dy$ za poljubno (Borelovo) funkcijo g , če integral obstaja.

TRDITEV: ZAKON POPOLNE PRIČAKOVANE VREDNOSTI

$$E(g(y)) = \int E(g(y) | X=x) f_X(x) dx$$

$$\text{DOKAZ: } \int_{\mathbb{R}} \int_{\mathbb{R}} g(y) f_{(Y|X)}(y|x) dy f_X(x) dx = \int_{\mathbb{R}} g(y) \underbrace{\int_{\mathbb{R}} f_{(Y|X)}(y|x) dx}_{f_X(x)} dy = E(g(y))$$

DEFINICIJA

Pogojna pričakovana vrednost $E(g(y)|X)$ je slučajna spremenljivka, podana s predpisom $E(g(y)|X)(\omega) = E(g(y)|X=X(\omega))$

b) ZGLED:

Naj bo (X, Y) normalen S.V. s parametri $\mu_X, \mu_Y, \sigma_X^2, \sigma_Y^2, \rho$. Tedaj je

$$f_{(Y|X)}(y|x) = \frac{\frac{1}{\sqrt{2\pi}} \frac{1}{\sigma_X \sigma_Y \sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)} \left(\left(\frac{y-\mu_Y}{\sigma_Y}\right)^2 - 2\rho \left(\frac{y-\mu_Y}{\sigma_Y}\right) \left(\frac{x-\mu_X}{\sigma_X}\right) + \left(\frac{x-\mu_X}{\sigma_X}\right)^2 \right)}}{\frac{1}{\sigma_X \sqrt{2\pi}} e^{-\frac{1}{2(1-\rho^2)} \left(\left(\frac{x-\mu_X}{\sigma_X}\right)^2 \right)}}$$
$$= \frac{1}{\sigma_Y \sqrt{1-\rho^2} \cdot \sqrt{2\pi}} e^{-\frac{1}{2(1-\rho^2)} \left(\rho^2 \left(\frac{y-\mu_Y}{\sigma_Y}\right)^2 - 2\rho \dots + \left(\frac{y-\mu_Y}{\sigma_Y}\right)^2 \right)}$$
$$= \frac{1}{\sqrt{2\pi} \sigma_Y^2 (1-\rho^2)} e^{-\frac{1}{2(1-\rho^2)} \left(\frac{(y-\mu_Y)^2}{\sigma_Y^2} - \rho^2 \frac{(x-\mu_X)^2}{\sigma_X^2} \right)}$$

Vidimo, da je $(Y|X=x) \sim N(\mu_Y + \rho \frac{\sigma_Y}{\sigma_X} (x-\mu_X), \sigma_Y^2 (1-\rho^2))$

\downarrow
prepoznam te korenja, nato
pa se to izpostaviti te
potence, da prepoznam
matematično upanje

Posebej je $E(Y|X=x) = \mu_Y + \rho \frac{\sigma_Y}{\sigma_X} (x-\mu_X)$ in $E(Y|X) = \mu_Y + \rho \frac{\sigma_Y}{\sigma_X} \cdot \frac{X-\mu_X}{\sigma_X}$ (temu izrazu pravimo regresija S.S. Y na S.S. X)

"Pomembitev je družina verjetnosti"

6 MOMENTI IN MOMENTNO-RODOVNA FUNKCIJA

"Naj bodo X s.s., $a \in \mathbb{R}$, $k \in \mathbb{N}$. k -ti moment s.s. X "okrog" a je prizakovana vrednost

$$m_k(a) = E((X-a)^k),$$

obstaja, tudi je $E(|X-a|^k) < \infty$

Momenti $m_k := E(X^k)$ so momenti okrog 0 (standardni momenti), če obstaja $E(X)$, momentom $m_k(E(X))$ pravimo CENTRALNI MOMENTI

če je X "zvezna" s.s. z gostoto f_X , je

$$m_k(a) = \int_{\mathbb{R}} (x-a)^k f_X(x) dx$$

če integral absolutno konvergira

"TRDITEV": če obstaja $m_n(a)$ za neki $n \geq 1$, obstajajojo tudi $m_k(a)$ za $1 \leq k \leq n$

$$\begin{aligned} \text{DOKAŽ}: E((X-a)^k) &= E(\underbrace{\mathbf{1}_{[-1,1]}(x-a)}_{\text{indeljiva funkcija}} |X-a|^k + \mathbf{1}_{(|X-a|>1)}(x-a) |X-a|^k) \\ &\leq 1 + E(|X-a|^n) < \infty \end{aligned}$$

$$\text{za zvezno: } \int_{-\infty}^{\infty} |x-a|^k f_X(x) dx = \int_{|x-a| \leq 1} |x-a|^k f_X(x) dx + \int_{|x-a| > 1} |x-a|^k f_X(x) dx$$

"TRDITEV": če obstaja $m_n(a)$ za neki $a \in \mathbb{R}$, obstajajojo tudi $m_n(b)$ za vse $b \in \mathbb{R}$

$$\begin{aligned} \text{DOKAŽ}: E(|X-b|^n) &= E(|X-a+a-b|^n) \leq E((|X-a|+|a-b|)^n) = \sum_{k=0}^n \binom{n}{k} E(|X-a|^k |a-b|^{n-k}) < \infty \\ &\quad \text{(abs. vsote je manjša od vsote abs. vrednosti)} \end{aligned}$$

$$\text{Hkrati preberemo } E((X-b)^n) = \sum_{k=0}^n \binom{n}{k} (a-b)^{n-k} \cdot m_k(a)$$

KOMENTAR: Sveda razumemo $m_0(a) = 1$.

"Motivacija za študij momentov pride iz naslednjega vprašanja:

Naj ima s.s. X in Y vse momente ($\forall k: E(|X|^k) < \infty, E(|Y|^k) < \infty$). Če velja $E(X^k) = E(Y^k)$ za vse k , ali sta potem X in Y enako porazdeljeni, torej ali je $P(X \in B) = P(Y \in B)$ za vse Borelove množice B .

porazdelitvena f. je $F: \mathbb{R} \rightarrow [0,1]$
 ↓
 neštevna množica
 če pa bomo gledali momente, ki so števna množice

↳ 12REK

Naj za s.s. X obstajajo vsi $E(X^k)$ in naj za neko število $t > 0$ konvergira vrsta $\sum_{k=0}^{\infty} \frac{t^k}{k!} E(X^k)$. Potem je porazdelitev s.s. X določena z momenti, če za drugo s.s. velja $E(X^k) = E(Y^k)$ za vse k , sta X in Y enako porazdeljeni.

[konvergenčni polmer je vsg. t]

↳ DEFINICIJA

MOMENTNO RODOVNA FUNKCIJA s.s. X je funkcija $t \mapsto E(e^{tx}) =: M_X(t)$

Definirana je za tista števila t , kjer PV obstaja (kjer je $E(e^{tx}) < \infty$). Če je X "zvezna" s.s. z gostoto $f_X(x)$, je $M_X(t) = \int e^{tx} f_X(x) dx$
Če je X diskretna, je $M_X(t) = \sum_x e^{tx} P(X=x)$

Če so vse "operacije" določene, je sredina

$$M_X(t) = E(e^{tx}) = E\left(\sum_{k=0}^{\infty} \frac{(tx)^k}{k!}\right) = \sum_{k=0}^{\infty} \frac{t^k}{k!} E(X^k)$$

\hookrightarrow Taylorjeva vrsta
za e^x

↳ 12REK

Naj $M_X(t)$ obstaja za $t \in (-\delta, \delta)$ za neki $\delta > 0$. Tedaj je M_X analitična okrog 0 (s konvergenčnim polmerom $\geq \delta$) in velja

$$M_X(t) = \sum_{k=0}^{\infty} \frac{t^k}{k!} E(X^k) \quad \text{za } t \in (-\delta, \delta)$$

Posebej je $M_X^{(k)}(0) = E(X^k)$ za vse k .

Sledi, da je porazdelitev s.s. X v tem primeru določena z momenti.

Op: [porazdelitev je določena s števnim naborom vrišč]

dovoljuje razvoj v Taylorjevo vrsto okrog 0, ki je konvergenten

Taylorjev razvoj

↳ TRDITEV: $M_{ax+bx}(t) = e^{tb} \cdot M_X(at)$

DOKAŽ: $E(e^{t(ax+bx)}) = e^{tb} \cdot E(e^{atx})$

↳ LEMA

Naj bosta $g: \mathbb{R} \rightarrow \mathbb{R}$ in $h: \mathbb{R} \rightarrow \mathbb{R}$ Borelovci funkciji. Če sta X in Y neodvisni SS., sta tudi $g(x)$ in $h(x)$ neodvisni.

DOKAŽ: $P(g(x) \in C \text{ in } h(y) \in D) = P(x \in g^{-1}(C) \text{ in } y \in h^{-1}(D)) = P(x \in g^{-1}(C)) \cdot P(y \in h^{-1}(D))$

↳ TRDITEV: Če sta X in Y neodvisni, je $M_{x+y}(t) = M_X(t) \cdot M_Y(t)$ (kje ima smisel)

$$\text{DOKAŽ: } M_{x+y}(t) = E\left(e^{tx} e^{ty}\right) = E(e^{tx}) \cdot E(e^{ty})$$

\hookrightarrow neodvisnost

7 LIMITNI IZREKI

IGRA: Imamo 3 košarice, pod enim je kroglica, drugi košarice premesa, uganit moraš pod katerim košarčkom je



če uganemo, je $X=10$, če zgrevšiš je $X=-6$

$$E(X) = 10 \cdot \frac{1}{3} + (-6) \cdot \frac{2}{3} = \frac{10}{3} - \frac{12}{3} = -\frac{2}{3}$$

"Prislušujem", da za veliko število n velja, da je $\frac{X(w_1) + X(w_2) + \dots + X(w_n)}{n}$ blizu $-\frac{2}{3}$

To želimo formalizirati kot $\lim_{n \rightarrow \infty} \frac{X(w_1) + \dots + X(w_n)}{n} = -\frac{2}{3}$

Vidimo, da to lahko interpretiramo le za NESTKONČNO ZAPOREDJE w_1, w_2, w_3, \dots

UPRAŠANJE: Ali se ne more zgoditi: $X(w_1) = X(w_2) = X(w_3) = \dots = 10$ (Tedaj bi bila limita $= 10$)

Ali se ne more zgoditi $X(w_1) = X(w_2) = \dots = -6$?

DA, lahko je

zato uvedemo verjetnost, da bo večjalo formalno

DA, lahko

REKLI BOMO: Verjetnost tistih neskončnih zaporedij (w_1, w_2, \dots) , za katere obstaja $\lim_{n \rightarrow \infty} \frac{X(w_1) + \dots + X(w_n)}{n}$ in je enaka $-\frac{2}{3}$ je 1.

28.3

KONSTRUKCIJA

Naj bo P verjetnost na σ -algebri \mathcal{F} podmnožici varčnega prostora Ω . Naj bo $S := \Omega \times \Omega \times \dots = \Omega^\mathbb{N} = \{(w_1, w_2, \dots) \mid w_i \in \Omega \text{ za } i \in \mathbb{N}\}$

"prostor" neskončnih zaporedij "elementarnih izidov" je Ω .

[P je del na vsaki Ω , ne pa na $\Omega^\mathbb{N}$]

Kaj so (bi bili) dogodki $\subset S$?

Želeli bi, da so vsaj množice oblike $\{\omega \mid w_i \in A_i\}$ kjer je $A_i \in \mathcal{F}$

\downarrow
dogodek na \mathcal{F}

Sledi, da morajo biti tudi $\{\omega \mid w_i \in A_1, \dots, w_n \in A_n\} = A_1 \times A_2 \times \dots \times A_n \times \Omega \times \Omega \times \dots$ dogodki

↳ nismo vreli neskončen, ker se v naravi
"skoraj gotovo" ne pojavijo

Od želenih verjetnosti P na "S" želimo, da je "pogoj" $w_i \in A_i$ neodvisen od prejnjih elementov w_1, w_2, \dots, w_{i-1} , hkrati pa želimo [neodvisnost je definirana preko verjetnosti]

[Tu je imamo SS. ampak imamo vzorčenje, katerega "porazdelitev" je bistven verjetnost]

da je vzorčenje $w_n \in \Omega$ narejeno po porazdelitvi P .

$$P(\{\omega \mid w_i \in A_i\} \mid w_1, \dots, w_{i-1}) = P(w_i \in A_i) = P(A_i)$$

↑ neodvisnost
↓ vzorčimo iz P

Formalno zahitevano $P(A_1 \times A_2 \times \dots \times A_n \times \Omega \times \Omega \times \dots) = P(A_1) \cdot P(A_2) \cdot \dots \cdot P(A_n)$

Izhaja se, da obstaja enotična verjetnost na najmanjji σ -algebri, ki vsebuje vse množice oblike $A_1 \times A_2 \times \dots \times A_n \times \Omega \times \Omega \times \dots$ in zato tudi zgornjemu pogoju (izrek Kolmogorova)

4 TRDITEV

Naj bo $X: \Omega \rightarrow \mathbb{R}$ poljubna s.s. in naj bodo $X_i: S \rightarrow \mathbb{R}$ definirane s predpisom $X_i(\omega) = X(\omega_i)$. Tedaj so X_i slučajne spremenljivke, ki so neodvisne in vse enako porazdeljene kot X .

KOMENTAR: To je formulacija neskončnega zaporedja neodvisnih replikacij danega slučajnega eksperimenta. !

OPOMBA: Dana množica S je neodvisna, če je vsaka njena končna podmnožica neodvisna.

DOKAZ:

$$\bullet \underset{\substack{\text{po def} \\ \text{IP}}} {\mathbb{P}}(X_1 \in B_1 \text{ in } \dots \text{ in } X_n \in B_n) = \mathbb{P}(X^{-1}(B_1) \times X^{-1}(B_2) \times \dots \times X^{-1}(B_n) \times \Omega \times \Omega \times \dots) =$$

$$X_i(\omega) \in B_i \iff \omega_i \in X^{-1}(B_i)$$

$$\mathbb{P}(X^{-1}(B_1) \cdot P(X^{-1}(B_2)) \cdot \dots \cdot P(X^{-1}(B_n)) =$$

$$\overset{\text{"narej"} \rightarrow}{=} P(X_1 \in B_1) \cdot \dots \cdot P(X_n \in B_n)$$

$$\text{Zgoraj smo že uporabili } P(X_i \in B_i) = P(X \in B_i)$$

5 Izrek

Naj bo X s.s. z prizakovano vrednostjo. Tedaj je

$$\boxed{\mathbb{P}\left(\{\omega \mid \lim_{n \rightarrow \infty} \frac{X(\omega_1) + \dots + X(\omega_n)}{n} = E(X)\}\right) = 1}$$

Splošneje velja

Izrek (Krepki zakon velikih števil Kolmogorova)

Naj bodo X_1, X_2, \dots NEP s.s. (definirane na nekem skupnem verjetnostnem prostoru) in naj obstaja $\mu := E(X_1)$. Tedaj je

$$\mathbb{P}\left(\{\omega \mid \lim_{n \rightarrow \infty} \frac{X_1(\omega) + \dots + X_n(\omega)}{n} = \mu\}\right) = 1$$

6 TRDITEV (Neenakost Markova)

Naj bo X s.s. s PV in $a > 0$. Velja $P(|X| > a) \leq \frac{1}{a} E(|X|)$

DOKAZ

$$|X| \geq a \cdot \mathbf{1}_{\{|X| > a\}} \implies E(|X|) \geq a \cdot P(|X| > a)$$

7 TRDITEV (Neenakost čebisevova)

$$\text{Naj bo } X \text{ s.s. z } E(X^2) < \infty \text{ in } \varepsilon > 0. \text{ Tedaj je } \mathbb{P}(|X - E(X)| > \varepsilon) \leq \frac{D(X)}{\varepsilon^2}$$

DOKAZ: $P(|X - E(X)| > \varepsilon) = P(|X - E(X)|^2 > \varepsilon^2)$, nato uporabiš neenakost Markova

8 Izrek (Sibki zakon velikih števil Markova)

Naj bodo X_1, X_2, \dots NEP s.s. z disperzijo $D^2 < \infty$ in prizakovano vrednostjo μ . Tedaj za vsa $\varepsilon > 0$ velja

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\left|\frac{X_1 + \dots + X_n}{n} - \mu\right| > \varepsilon\right) = 0$$

↓
s.s.
konstanta in tudi s.s.

OPOMB: SS. $\bar{X} = \bar{X}^{(n)} = \frac{x_1 + \dots + x_n}{n}$ pravimo vzorčno povprečje

$$\text{DOKAŽ}: \text{Ker je } \mu = E(\bar{X}) \quad (E(\bar{X}) = \frac{E(x_1) + \dots + E(x_n)}{n} = \frac{n\mu}{n} = \mu) \quad , \text{je} \quad P(|\bar{X} - \mu| > \varepsilon) \leq \frac{D(\bar{X})}{\varepsilon^2} = \frac{\sum_{i=1}^n D(x_i)}{n^2 \cdot \varepsilon^2} = \frac{n \cdot \sigma^2}{n^2 \cdot \varepsilon^2} = \frac{\sigma^2}{n \cdot \varepsilon^2} \xrightarrow{n \rightarrow \infty} 0$$

neenakost čebiščeca

OPOMB: Dovolj je, da so SS. nekorlirane [neke majorante je omenjena]

↳ ZGLED

Naj bo X_1, X_2, \dots nep. $Ber(1, p)$. Pisimo $\hat{p} := \bar{X}$: delež enic v n poskusih

$$\text{Velja } D(X_i) = p(1-p) \text{ in } E(X_i) = p \text{ za vsi. Ocena iz dokaža še: } P(|\hat{p} - p| > \varepsilon) \leq \frac{p(1-p)}{n\varepsilon^2} \xrightarrow{\substack{\text{očitimo s kemično parabolo} \\ \text{ocena brez neznanih parametrov, GREAT!}}} \frac{1}{4n\varepsilon^2} \rightarrow \text{ocena brez neznanih parametrov, GREAT!}$$

Pripravljamo $n=10000$ in $\varepsilon = 0,05$. Dobimo

$$P(|\hat{p} - p| > 0,05) \approx \frac{1}{100}$$

$\xrightarrow{\substack{\text{z verjetnostjo vsaj 99\% se bo razlikovalo vedno od prizakovane} \\ \text{za vsaj 0,05 [pripr. 0,45 \leftrightarrow 0,55]}}}$

ABSTRAKTNA | KONVERGENCA ZAPOREDIJ SS.

Naj bodo y, y_1, y_2, \dots ss. definirane na skupinem verjetnostnem prostoru. Pravimo, da $(y_n)_{n \in \mathbb{N}}$ konvergira k y

• VERJETNOSTNO [pisemo: $y_n \xrightarrow{n \rightarrow \infty} y$] , če $\forall \varepsilon > 0 : \lim_{n \rightarrow \infty} P(|y_n - y| > \varepsilon) = 0$

• SKORAJ GOTovo [pisemo $y_n \xrightarrow{n \rightarrow \infty} y$] , če $P(\exists \lim_{n \rightarrow \infty} y_n = y) = 1$ → v analizi je to konvergenca po točkam!

Vidimo, da kv. pravi $\bar{X} \xrightarrow{\text{sg}} \mu$

še: pravi $\bar{X} \xrightarrow{P} \mu$

↳ LEMA: $\{\omega \mid \exists \lim_{n \rightarrow \infty} y_n(\omega) = y(\omega)\}$ je dogodek

DOKAŽ: $A = \{\omega \mid \forall \varepsilon > 0 \exists N \in \mathbb{N} \text{ da za } \forall n \in \mathbb{N}: |y_n(\omega) - y(\omega)| < \varepsilon\}$

$$= \bigcap_{\varepsilon > 0} \bigcup_{N=1}^{\infty} \bigcap_{n=N}^{\infty} \{\omega \mid |y_n(\omega) - y(\omega)| < \varepsilon\}$$

$$= \bigcap_{k=1}^{\infty} \bigcup_{N=1}^{\infty} \bigcap_{n=N}^{\infty} \{\omega \mid |y_n(\omega) - y(\omega)| < \frac{1}{k}\}$$

je dogodek

↓
zvezna funkcija s spremenljivko
je ss.

je dogodek

po tem pa imamo stevni poset, ikemo ugotovili
in stevni poset in ga to ševedno dogodek

↳ TRDITEV: $(y_n \xrightarrow{\text{sg}} y) \implies (y_n \xrightarrow{P} y)$

→ podajajoči veriga množic?

DOKAŽ: Pisemo $A_k = \{\omega \mid y_k(\omega) \in A\}$, ker je $A_1 \supseteq A_2 \supseteq A_3 \supseteq \dots$. Pri privetku sg. konvergencije sledi: $\forall k : P(A_k) = 1$. Pri danem k to pomeni:

$$1 = P\left(\bigcap_{N=1}^{\infty} \bigcap_{n=N}^{\infty} \{y_n(\omega) \in A\}\right) = \lim_{N \rightarrow \infty} P\left(\bigcap_{n=N}^{\infty} \{y_n(\omega) \in A\}\right)$$

navezati logično
verigo v N

$$P(\text{poset}) = P(\text{članek}) \leq 1$$

↓ konv ↓ sendvič

Po izreku o sendviču je $\lim_{N \rightarrow \infty} P(\{y_n(\omega) \in A\}) = 1$. To je konvergencija v verjetnosti. ■

↪ TRDITEV

Naj bodo y_1, y_2, \dots ss definirane na skupnem verjetnostnem prostoru in naj bo $g : \mathbb{R} \rightarrow \mathbb{R}$ zvezna (dovolj je, da je g zvezna na taki Borelovji B), da je začenj $P(Y \in B) = 1$

$$(1) \text{ Če } y_n \xrightarrow{\text{zvezne funkcije ohranjajo konvergenco}} y; g(y_n) \xrightarrow{\text{zvezne funkcije ohranjajo konvergenco in limito}} g(y)$$

$$(2) \text{ Če } y_n \xrightarrow{P} y; g(y_n) \xrightarrow{P} g(y)$$

DOKAZ: 1) zvezne funkcije ohranjajo konvergenco \rightarrow PREUČI

2) Najprej dokazemo, da $y_n \xrightarrow{P} y \iff$ vsako zaporedje zaporedja y_n ima nadaljnje podzaporedje, ki k y konvergira skoraj gotovo.

Potem pa lahko uporabimo 1)

↪ ZGLED - Monte Carlo integracija

Želimo "integrirati" $\int f(x) dx$, kjer je f zvezna funkcija. Ključno je to numerično "težko" imamo na voljo M-C "integracijo". Prepoznamo $\int f(x) dx = E(f(X))$ za $X \sim U(0,1)$. Če je x_1, x_2, \dots zaporedje NEP $U(0,1)$ ss., je tudi $f(x_1), f(x_2), \dots$ zaporedje NEP ss.

$$\text{KZVS: } \frac{f(x_1) + \dots + f(x_n)}{n} \xrightarrow[n \rightarrow \infty]{\text{s.g.}} E(f(U(0,1))) = \int f(x) dx$$

To lahko uporabimo v praksi s pomočjo simulacije NEP vzorčenja iz $U(0,1)$. Temu pravimo (konstrukcijo) prevođljivih števil.

CENTRALNI LIMITNI IZREK

↪ Naj bo Φ k.p.f. standardne normalne porazdelitve, $\Phi(t) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^t e^{-\frac{t^2}{2}} dt$. Naj bo X_1, X_2, \dots zaporedje NEP ss. z disperzijo σ^2 in pričakovano urednostjo μ . Tedaj za $t \in \mathbb{R}$ velja

$$\lim_{n \rightarrow \infty} P\left(\frac{\bar{x}_1 + \dots + \bar{x}_n - \mu}{\sigma/\sqrt{n}} \leq t\right) = \Phi(t) \quad (= P(N(0,1) \leq t))$$

Ni varčno, karščna je porazdelitev ss. \bar{x}_i , varčni sta σ^2 in μ

↪ POSLEDICA: Za $a < b \in \mathbb{R}$ je $\lim_{n \rightarrow \infty} P\left(\frac{\bar{x}_1 + \dots + \bar{x}_n - \mu}{\sigma/\sqrt{n}} \in (a, b)\right) = \Phi(b) - \Phi(a) = P(N(0,1) \in (a, b))$

↪ $\frac{\bar{x}_1 + \dots + \bar{x}_n - \mu}{\sigma/\sqrt{n}}$ je standardizacija vzorčnega povprečja

↪ CCI pravi, da k.p.f standardiziranih vzorčnih povprečij po točkah konvergirajo k k.p.f. od $N(0,1)$

Ponovi si analizo konvergencije po točkah!

↪ V praksi CCI uporabljamo za ocenjevanje verjetnosti $P(\bar{x} \in [a, b])$ (torej za ocenjevanje porazdelitve ss. \bar{x}) za "VELIKA" števila n : $P(\bar{x} \in (c, d)) = P\left(\frac{\bar{x}-\mu}{\sigma/\sqrt{n}} \in \left(\frac{c-\mu}{\sigma/\sqrt{n}}, \frac{d-\mu}{\sigma/\sqrt{n}}\right)\right) = \Phi\left(\frac{d-\mu}{\sigma/\sqrt{n}}\right) - \Phi\left(\frac{c-\mu}{\sigma/\sqrt{n}}\right)$

Pravimo, da je za veliko št. n vzorčno povprečje \bar{x} porazdeljeno približno normalno, $\bar{x} \sim N(\mu, \sigma^2/n)$

TRIVIALNO = dolat je lahko narejen v eni vrstici

Dokaz "sepa", saj je v naravnih težjih dobiti momentna ročevne funkcije in podobno?

IZREK O "ZVEZNOSTI"

Naj bo y_1, y_2, \dots zaporedje ss. z momentno-redovnimi funkcijami (na $(-\infty, \infty)$). Če velja

$$t \in (-\infty, \infty) : \lim_{n \rightarrow \infty} M_{y_n}(t) = e^{t^2/2}$$

potem velja za $t \in \mathbb{R}$: $\lim_{n \rightarrow \infty} P(y_n \leq t) = F(t)$

OPOMBA : $M_{N(0,1)}(t) = e^{t^2/2}$ (za vsi t)

Torej ker momentno-redovna funkcija enolično določa porazdelitev, lahko samo določeno daje $\lim_{n \rightarrow \infty} M_{\bar{x}_n}(t) = e^{t^2/2}$

DOKAZ CLI (pri privzetku obstaja M_x , na nekem intervalu okrog 0.)

$$\text{Pišimo } y_n = \frac{\bar{x}_n - \mu}{\sigma/\sqrt{n}} = \frac{x_1 + x_2 + \dots + x_n - n\mu}{\sigma\sqrt{n}} = \frac{1}{n} \sum_{i=1}^n \frac{x_i - \mu}{\sigma}$$

$$\Rightarrow M_{y_n}(t) = M_{\frac{1}{n} \sum_{i=1}^n \frac{x_i - \mu}{\sigma}}(t) = M_{\sum_{i=1}^n \frac{x_i - \mu}{\sigma}}\left(\frac{t}{\sqrt{n}}\right) = \left(M_{\frac{x_1 - \mu}{\sigma}}\left(\frac{t}{\sqrt{n}}\right)\right)^n = \left[1 + E\left(\frac{x_1 - \mu}{\sigma}\right)\frac{t}{\sqrt{n}} + \frac{1}{2} E\left(\left(\frac{x_1 - \mu}{\sigma}\right)^2\right)\left(\frac{t}{\sqrt{n}}\right)^2 + \left(\frac{t}{\sqrt{n}}\right)^3 g\left(\frac{t}{\sqrt{n}}\right)\right]^n =$$

↓
 neodvisnost
 x_i
 enako
 porazdeljeni
 momentna je
 analitična, torej
 ima Taylorjevo
 vrsto

$$= \left(1 + \frac{1}{2n} t^2 + \left(\frac{t}{\sqrt{n}}\right)^3 g\left(\frac{t}{\sqrt{n}}\right)\right)^n$$

$$\lim_{n \rightarrow \infty} (1 + a_n)^{b_n} = e^{\lim_{n \rightarrow \infty} (a_n b_n)}$$

↓
 $= e^{\lim_{n \rightarrow \infty} \left(\frac{1}{2} + \frac{t^2}{2\sqrt{n}} g\left(\frac{t}{\sqrt{n}}\right)\right)}$
 g je kvadratna v 0, torej ima g določeno vrednost v 0

Uporabimo lahko izrek o zveznosti:

DEFINICIJA

Zaporedje ss. konvergira k ss. Y v porazdelitvi (v zakonu), če velja $\lim_{n \rightarrow \infty} F_{y_n}(x) = F_Y(x)$ za vsi x , kjer je F_Y zvezna.

SKLEPNA STATISTIKA

„Osnovni problem sklepne statistike je za "neznano" funkcijo $X: \Omega \rightarrow \mathbb{R}$ iz "uzorca" njenih vrednosti sklepati za njeno "globalno obnašanje".

4 ZGLED

① Naj bo Ω množica točk na travnih Golice in $X(\text{točka}) = \# \text{ narcis v krogu polmera } m$

Uzorec: naključno izbranih n točk: w_1, w_2, \dots, w_n

"Ocenja": $\frac{X(w_1) + \dots + X(w_n)}{n}$

S to oceno ocenjamo prizakovano vrednost GLEDE NA PORAZDELITEV na Ω , s katero vzorcimo

② Naj bo Ω množica polnoletnih žensk s previsokim LDL holesterolom in $X(\omega) = (\text{nivo "pred terapijo"} - \text{nivo "po terapiji"})(\omega)$
z $\frac{X_1(\omega) + \dots + X_n(\omega)}{n}$ bomo ocenjevali prizakovano vrednost $E(X)$ GLEDE NA VZOREČENJE P NA Ω

Temeljna predpostavka je, da je Ω opremljen (s σ -algebro in) z verjetnostjo. Iz lastnosti uzorca polem sklepamo na lastnosti porazdelitvenega zakona P_X ss. X . Za kvalitetno sklepanje potrebujemo VNAPREJŠNJE PREDPOSTAVKE na (obliko) P_X

1 STATISTIČNI MODEL

↪ Naj bo $X: \Omega \rightarrow \mathbb{R}$ proučevana S.S.. Statistični model je MNOŽICA DOPUSTNIH POZADEDELITVENIH ZAKONOV za X . Verjamemo (prijavljamo), da je P_X ena izmed njih. Statistično sklepajo lahko predstavimo kot metodo za izbor tiste dopustne porazdelitve, ki je danemu vzorcu najbolje (...) prilga

↪ glede na neke pogoje??

↪ ZGLED

Pojavil se je ponarejen kovanec s $p_1 = \frac{3}{5}$, uradno pa imajo $p_0 = \frac{1}{2}$. Najdemo kovanec, ga 1000 krat vržemo in zabeležimo. $\frac{2}{7}$ cifer. SKLEP: kovanec je pošten

↪ Porazdelitev S.S. je enolično določena z njeni k.p.f., torej statistični model lahko enacimo z neko podmnožico \mathcal{F} množice vseh (abstraktnih) k.p.f. Pri izbiri modela nas vodijo različni motivi (zgodovina, empirično preizkušanje), med njimi v praksi izstopa racunska (in teoretična) preprostost. Po izbiri modela je steknja statistika EKSAKTNA VEDA.

↪ ZGLEDI MODELov

• BERNOULLIJEV MODEL

Prijavljamo, da ta proučevamo slugovo spremenjivko [PSS] X velja $X \sim \text{Ber}(1, p)$ za neki neznani $p \in (0, 1)$. Torej je \mathcal{F} družina vseh funkcij: $F_p: \mathbb{R} \rightarrow [0, 1]$



• NORMALNI MODEL

Za PSS X prijavljamo: $X \sim N(\mu, \sigma^2)$ za neko neznano $\mu \in \mathbb{R}$ in $\sigma \in (0, \infty)$

$$\mathcal{F} = \{F_{N(\mu, \sigma^2)} \mid \mu \in \mathbb{R}, \sigma^2 \in (0, \infty)\}$$
$$F_{N(\mu, \sigma^2)}(x) = \int_{-\infty}^x (\sigma^{-1} \cdot \sqrt{2\pi})^{-n} e^{-\frac{1}{2\sigma^2}(t-\mu)^2} dt$$

• ZVEZNI MODEL

Za PSS X prijavljamo $P(X=x)=0$ za vse x ; \mathcal{F} je množica vseh ZVEZNIH k.p.f.

• ABSOLUTNO ZVEZNI MODEL

Za PSS X prijavljamo gostoto (glede na Lebesguevo mero)

• POLNI MODEL

\mathcal{F} = vse k.p.f.

DEFINICIJA

Model F je parametričen, če je F mogoče parametrizirati s končnim naborom realnoštevinskih parametrov. Tehnično to pomeni, da je F v bijekciji korenšpondenci z ustreznim podmnožico $\Theta \subset \mathbb{R}^d$ (za neki d): obstaja bijekcija $F \leftrightarrow \Theta$

\downarrow
theta (parametričen prostor)

Tipično želimo, da imam vložitev $\Theta \leftrightarrow$ prostor vseh k.p.f. še dodatne lastnosti (gladka vložitev gladih mnogoterosti)
Če model ni parametričen, je neparametričen.

Parametrična modela sta Bernoullijev in Normalni. V parametričnih modelih lahko statistično sklepanje predstavimo kot metodo za izbiro tistega parametra $\theta \in \Theta$, pri katerem se ustrezena porazdelitev najbolje prilega danemu vzorcu

Omenimo se parametrični model 1b.

Verjamemo, da je PSS $X \sim \binom{x_0 \ x_1 \ \dots \ x_d}{p_0 \ p_1 \ \dots \ p_d}$ za fiksne $x_0 < x_1 < x_2 < \dots < x_d$ in neznanne parametre p_0, p_1, \dots, p_d

Ta je $\Theta = \{(p_0, p_1, \dots, p_d) \mid \forall j : p_j > 0 \text{ in } \sum_{j=0}^d p_j = 1\}$

To je STANDARDNI D-RAZSEŽENI SIMPEKS V $(0, \infty)^{d+1}$

Temu modelu pravimo tudi kategorični model z $d+1$ kategorijami

2 TOČKOVNO OCENJEVANJE

• Naj bo $X: \Omega \rightarrow \mathbb{R}$ PSS. Recimo, da nas zanima pričakovana vrednost $E(X)$. Ocenili jo bomo (tipično) s povprečjem

$$\frac{X(w_1) + \dots + X(w_n)}{n} = \bar{X}(n)$$

Na vzorcu $\omega = (w_1, \dots, w_n) \in \Omega^n$, kar je prostor vzorcev (realizacij) velikosti n . Če pišemo $S = \Omega^n$ in Ω^n opremimo z običajno (produktno) verjetnostjo in definiramo $X_i: S \rightarrow \mathbb{R}$ s predpisom $X_i(\omega) = X(w_i)$, so X_1, \dots, X_n NEP SS., use porazdeljene enako kot X . Slučajnemu vektorju (X_1, \dots, X_n) pravimo standardni neodvisni slučajni vzorec.

Slučajni spremenljivki $\bar{X}: S \rightarrow \mathbb{R}$, $\bar{X} = \frac{X_1 + \dots + X_n}{n}$ pravimo vzorčno povprečje. Z njim ocenjujemo pričakovano vrednost $E(X) = E(X_1) = \dots = E(X_n)$

DEFINICIJA

Naj bo c (neznani) karakteristika porazdelitve PSS X (na primer $E(X)$, $D(X)$, $E(X^2)$, $P(X \leq 2)$). Cenilka karakteristike c je (Borelov) funkcija slučajnega vzorca, s katero ocenjujemo c . Cenilka je določena s Borelovovo funkcijo $T: \Omega^n \rightarrow \mathbb{R}$ ($\text{za } T(x_1, \dots, x_n) = \frac{x_1 + \dots + x_n}{n} \text{ je } T(x_1, x_2, \dots, x_n) = \bar{X}$)

DEFINICIJA

Cenilka $T(x_1, \dots, x_n)$ je NEPRISTRANSKA za c v modelu F , če velja $E(T(x_1, \dots, x_n)) = c(F)$ za $\forall F \in \mathcal{F}$ in usako n-tico $x_1, x_2, \dots, x_n \stackrel{\text{NEP}}{\sim} F$.

ZGLEDI

• V Poissonovem modelu, kjer $X \sim \text{Poiss}(\lambda)$ za nek neznan parameter $\lambda \in (0, \infty)$, je \bar{X} nepristranska cenilka za $D(X)$.

Res: Naj bodo $x_1, \dots, x_n \stackrel{\text{NEP}}{\sim} \text{Poiss}(\lambda)$

$$E(\bar{X}) = \frac{1}{n} \cdot n \cdot E(\text{Poiss}(\lambda)) = \lambda = D(\text{Poiss}(\lambda))$$

$$\text{Drobni tisk: } P(\text{Poiss}(\lambda) = k) = e^{-\lambda} \cdot \frac{\lambda^k}{k!}$$

• \bar{X} je nepristranska cenilka za pričakovano vrednost v kakršenkoli modelu s pričakovanimi vrednostmi

$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{X})^2$ je nepristranska cenilka za disperzijo v kakršenkoli modelu z drugimi momenti:

$$\sum_{i=1}^n (x_i - \bar{X})^2 = \sum_{i=1}^n x_i^2 - 2\bar{X} \sum_{i=1}^n x_i + n\bar{X}^2 = \sum_{i=1}^n x_i^2 - n\bar{X}^2$$

$$\text{Pišimo } \mu = E(X_i) \text{ in } \sigma^2 = D(X_i)$$

$$E\left(\sum_{i=1}^n (x_i - \bar{X})^2\right) = n(\sigma^2 + \mu^2) - n \cdot (D(\bar{X}) + E(\bar{X})^2) = n(\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right) = (n-1)\sigma^2$$

$$\downarrow \quad E(\sigma^2) = D(\bar{X}) + E(\bar{X})^2$$

• kar smo definirali za realistične cenilke, na očiten način posplošimo na vektorske cenilke.

Na primer: $T(x_1, \dots, x_n) = (\bar{X}, S^2)$ je nepristranska cenilka za $c(X) = (E(X), D(X))$

↳ kako bi primerjali dve nepristranski cenilki?

Naj bosta torej U in V nepristranski cenilki karakteristike $c(x) = c(F)$ v dlanem modelu

$$\text{ZGLED: } \rightarrow U(x_1, \dots, x_n) = \bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n}$$

$$\rightarrow V(x_1, \dots, x_n) = x_{q_2} \quad (n \geq 4)$$

→ vzamemo samo en podatek

$$\rightarrow W(x_1, \dots, x_n) = \begin{cases} \frac{x_1 + x_2 + \dots + x_n}{\frac{n(n+1)}{2}} & ; n \text{ je lino število} \\ \frac{x_1 + x_2 + \dots + x_n}{n} & ; n \text{ je sodo število} \end{cases}$$

→ vzamemo samo pol podatkov

To so nepristranske cenilke za $c(x) = E(x)$

Za menjanje "kakovosti" cenilka nas zanimala nepristranskošč in tudi odstopanje vseh vrednosti od izbrane cenilke. Odstopanja "merimo" v verjetnosti z disperzijo.

Priuzemimo F z disperzijo

$$D(U) = D(\bar{x}) = \frac{D(x'')}{n} = \frac{D(F)}{n} \quad \text{če } x_i \stackrel{\text{NPF}}{\sim} F$$

$$D(V) = D(x'') = D(F)$$

$$D(W) = \begin{cases} \frac{D(F)}{(n(n+1)/2)} & ; n \text{ lino} \\ \frac{D(F)}{n/2} & ; n \text{ sodo} \end{cases}$$

(a) ... normalni model

$$(b) \dots F = \{x_n^2 \mid n \in \mathbb{N}\} = \{\Gamma(\frac{n}{2}, \frac{1}{2}) \mid n \in \mathbb{N}\}$$

$$D(X_n^2) = 2 \cdot n$$

Vidimo, da je $F \mapsto D(F)$ funkcija $F \rightarrow [0, \infty)$ [spominja se glede na n]

DEFINICIJA

Uima enakomerno manjjo disperzijo od V (na F) če $D(U(x_1, \dots, x_n)) \leq D(V(x_1, \dots, x_n))$ za vse $F \in \mathcal{F}$ in vse $x_1, \dots, x_n \stackrel{\text{NPF}}{\sim} F$

KOMENTAR: Imamo "dovdij velik" nabor standardnih modelov, pri katerih obstajajo nepristranske cenilke z enakomerno najmanjjo disperzijo (statistika 1)

OBNAŠANJE CENILK ZA VELIKE VZORCE

• Priuzemimo neskončno zaporedje $x_1, x_2, \dots \stackrel{\text{NPF}}{\sim} F \in \mathcal{F}$. Naj bo $c(F)$ ocenjevana karakteristika. Zaporedje cenilk $U_n(x_1, \dots, x_n)$ je nepristransko za c v limiti, če velja $\forall F: \lim_{n \rightarrow \infty} E(U_n(x_1, \dots, x_n)) = c(F)$

• ZGLED: $U_n = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$ (kot zaporedje cenilk za disperzijo) je nepristransko v limiti ($U_n = \frac{n-1}{n} S^2$)

• DEFINICIJA: Zaporedje cenilk U_n za c v modelu F je DOSIEDNO ("consistent") če $\forall F \in \mathcal{F} \forall x_1, \dots, x_n \stackrel{\text{NPF}}{\sim} F$:

$$U_n(x_1, \dots, x_n) \xrightarrow{P} c(F)$$

• ZGLED: V $\{N(\mu, \sigma^2) \mid \mu > 0\}$ ocenjujemo $\frac{1}{\mu}$; $\frac{1}{\bar{x}}$ je clostvedna

METODE ZA KONSTRUKCIJO CENILK

① METODA MOMENTOV

Filozofija metode momentov je, da vse kar je mogoče izraziti z momenti, ocenjujemo preko (standardnih) cenilk za momente.

$$\text{Spomnimo se: } m_k = E(x^k) = \int_{-\infty}^{\infty} x^k f_x(x) dx$$

$$\text{Standardna cenilka za } m_k: \hat{m}_k(x_1, \dots, x_n) = \frac{1}{n} \sum_{i=1}^n x_i^k$$

To je nepristranska cenilka za m_k , ki tvori (krepko) dosledno zaporedje cenilk za m_k v vsakem modelu s k -imi momenti

Če ocenjujemo $c(F) = g(m_1, m_2, \dots, m_r)$, bi po metodi momentov vzeli cenilko $g(\hat{m}_1, \hat{m}_2, \dots, \hat{m}_r)$ [$1 \leq k \leq r$]. Če je g zvezna, sledi (krepko) dosledno zaporedje cenilk.

Tipično (v praksi) postopamo takole:

Prizemimo, da $\mathcal{F} \leftrightarrow (\mathbb{H}^{\text{opp}} \text{ CIR})$

$$\text{Tedaj za } 1 \leq k \leq r \text{ velja: } m_k = m_k(v_1, \dots, v_r)$$

[momenti so funkcije parametrov]

Prizemimo, da je sistem enacib

$$m_1 = m_1(v_1, \dots, v_r)$$

:

$$m_r = m_r(v_1, \dots, v_r)$$

mogoče resiti na $v = (v_1, \dots, v_r)$: $v = g(m_1, \dots, m_r)$

Potem po metodi momentov ocenjujemo v s cenilko

$$\hat{v} = g(\hat{m}_1, \dots, \hat{m}_r)$$

in vse druge funkcije parametrov v preko \hat{v} .

tukaj iščemo "inverz", zato imamo za definicijo območje odprtih m_i , da lahko uporabimo izrek o implicitni funkciji, da si inverz zagotavljamo

funkcija: $(\mathbb{H}^{\text{opp}} \xrightarrow{c(F)} \mathbb{R})$
inverz g : slika $\rightarrow (\mathbb{H})$

DOSLEDNOST sledi: n? S2V5
saj $m_k = \frac{1}{n} \sum_{i=1}^n x_i^k \xrightarrow{?} E(x^k) = \mu_k$?

ZGLED

Vzemimo $\mathcal{F} = \{ \text{Beta}(a, b) \mid a, b \in (0, \infty) \}$

$$f_{\text{Beta}(a,b)}(x) = \frac{1}{B(a,b)} x^{a-1} (1-x)^{b-1}$$

$$\text{Imer je } B(a,b) = \int_0^1 x^{a-1} (1-x)^{b-1} dx = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}$$

S tem modelom pogosto modeliramo OMEJENE ZVEZNE SS.

$$m_k = \frac{1}{B(a,b)} \int_0^1 x^{atk-1} (1-x)^{bt-1} dx = \frac{B(atk, bt)}{B(a,b)} = \frac{\Gamma(atk)\Gamma(bt)}{\Gamma(atk+bt)\Gamma(a+b)} = \frac{(atk-1)\dots(1)}{(atk+bt-1)\dots(1)}$$

$$\text{Posebej je } m_1 = \frac{a}{a+b} \quad m_2 = \frac{(a+1)a}{(a+1)(b+1) \cdot (a+b)}$$

$$m_1^a = 1 + \frac{b}{a} \quad \text{in} \quad m_2^a = m_1^a \cdot \left(1 + \frac{b}{a}\right)$$

$$\begin{array}{l} \uparrow \\ b = a(m_1^a - 1) \end{array} \quad \begin{array}{l} \uparrow \\ (m_2^a m_1^a - 1)(a + 1) = b \end{array}$$

$$a(m_1^a m_2^a - 1) = 1 - m_2^a m_1^a$$

$$\Rightarrow a = \frac{1 - m_2^a m_1^a}{m_2^a m_1^a - 1} \quad b = a \cdot (m_1^a - 1)$$

$$a = \frac{m_1^a (m_2^a - 1)}{m_2^a - 1} = \frac{m_1^a (m_2^a - 1)}{m_2^a - 1} \quad \text{disperzija Beta funkcije} > 0$$

$$\Rightarrow \hat{a} = \frac{\hat{m}_1^a (\hat{m}_2^a - 1)}{\hat{m}_2^a - 1} \quad \hat{b} = \hat{a} \left(\frac{1}{\hat{m}_1^a} - 1 \right)$$

② METODA NAJVEČJEGA VERJETJA (the method of maximum likelihood)

• UVODNI ZGLED

Pri našem vprašanju, ali bi pri $217/1000$ cifrah v Bernoullijevem eksperimentu reje podprtji $p_0 = \frac{1}{2}$ ali $p_1 = \frac{2}{3}$, bi lahko rekli, da bi podprtji $p_0 = \frac{1}{2}$, ker je $P(B(1000, \frac{1}{2}) = 217) > P(B(1000, \frac{2}{3}) = 217)$

Temu režemo metoda največjega verjetja

• Prižemimo polni Bernoullijev model, $\Theta = \{0, 1\}$, in prižemimo, da imamo v vzorcu velikosti n k-enec. Za oceno za p po MNV bi uželi tisti \hat{p} , pri katerem je $P(B(n, \hat{p}) = k) = L(\hat{p})$ maksimalna

$$\text{Seveda } L(p) = \binom{n}{k} p^k (1-p)^{n-k}. \text{ Velja } L'(p) = \binom{n}{k} (k \cdot p^{k-1} (1-p)^{n-k} - (n-k) p^k (1-p)^{n-k-1})$$

Očitno je $L'(p) = 0 \iff p - \frac{n-k}{n-p} = 0 \iff k - np = 0 \iff p = \frac{k}{n}$

Zlahka se prepričamo, da ima L v $\hat{p} = \frac{k}{n}$ maksimum (Prepričajte se, da je lin. konkavna)

Pravimo, da je cenilka $\hat{p} = \frac{k}{n}$ cenilka za p po MNV. Preberemo $\hat{p} = \bar{x}$ za $x_1, x_2, \dots, x_n \stackrel{\text{iid}}{\sim} \text{Bernoulli}(p)$

• DEFINICIJA

Prižemimo parametrični model s $\Theta \subset \mathbb{R}^r$ in naj bodo $f(\cdot; \vartheta)$ gostota (v zveznem primeru) oziroma verjetnostne funkcije (v diskretnem primeru) dopustnih porazdelitev. Funkcija verjetja za vzorec velikosti n je preslikava $L: \mathbb{R}^n \times \Theta \longrightarrow [0, \infty)$,

$$L(x_1, \dots, x_n; \vartheta) = f(x_1; \vartheta) \cdots f(x_n; \vartheta)$$

Kot funkcija (realizacija) vzorca je to seveda gostota (\therefore) sl. vzorca (x_1, \dots, x_n) pri parametru ϑ . V teoriji verjetja L obravamo kot funkcijo parametra ϑ .

• Pravimo, da je $\hat{\vartheta}$ OCENA za ϑ na vzorcu $x = (x_1, \dots, x_n)$ po MNV, če velja: $L(x, \hat{\vartheta}) = \max_{\vartheta} L(x; \vartheta)$

• ZGLED

① NEP-BERNOULLIJEV MODEL $\Theta = \{0, 1\}$

$$\begin{pmatrix} 1 & 0 \\ p & 1-p \end{pmatrix}$$

$$f(x, \vartheta) = p^x (1-p)^{1-x}$$

$$L(x_1, \dots, x_n; p) = p^{\sum x_i} (1-p)^{n-\sum x_i}$$

$$\text{za } \hat{p}(x) = \frac{\sum x_i}{n} \text{ velja } L(\hat{p}(x)) = \max_{p \in [0, 1]} L(p)$$

naseljen na $[0, 1] = \Theta$

L moramo obravnavati kot funkcijo na zaprtem intervalu

KOMENTAR: • Če $\sum x_i = 0$, $L(p) = (1-p)^n$

• Če $\sum x_i = n$, je $L(p) = p^n$

Vidimo, da moramo dopustiti $\hat{\vartheta} \in \overline{\Theta}$, če je mogoče L razširiti na $\overline{\Theta}$. ▶

② NEP-NORMALNI MODEL

$$\Theta = \mathbb{R} \times (0, \infty); f(x; \mu, \sigma^2) = (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum (x_i - \mu)^2}$$

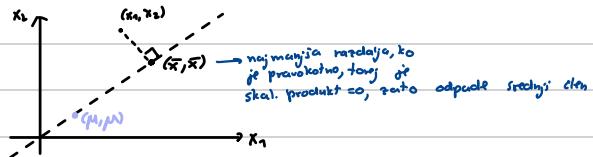
$$\Rightarrow L(x_1, \dots, x_n; \mu, \sigma^2) = (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum (x_i - \mu)^2}$$

je samo ta

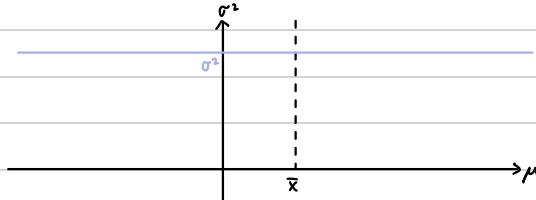
DN: obravnavanje maksimizacije problem v duh sprejemljivkata

$$\sum_{i=1}^n (x_i - \mu)^2 = \sum_{i=1}^n (x_i - \bar{x} + \bar{x} - \mu)^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu)^2$$

Iz zapisa v Temenski obliku preberemo, da ima $\mu \mapsto \sum_{i=1}^n (x_i - \mu)^2$ minimum $\sum_{i=1}^n (x_i - \bar{x})^2$, ki je dosegren v $\hat{\mu} = \bar{x} = \frac{\sum x_i}{n}$



$$\Rightarrow L(x; \mu, \sigma^2) \leq (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \bar{x})^2}$$



Maksimizacijski problem za $(\mu, \sigma^2) \mapsto L(x; \mu, \sigma^2)$ je reducirjan na maksimizacijski problem za

$$\sigma^2 \mapsto (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \bar{x})^2} =: A(\sigma^2)$$

Vidimo, da je $A'(\sigma^2) = 0 \iff -\frac{n}{2}(\sigma^2)^{-\frac{n}{2}-1} + (\sigma^2)^{-\frac{n}{2}} \left(-\frac{1}{2} \cdot \frac{-1}{(\sigma^2)^2} \sum_{i=1}^n (x_i - \bar{x})^2 \right) = 0$ [tu smo exp izpostavili in pakravali]

$$\iff \sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Stedi, da ima $(\mu, \sigma^2) \mapsto L(x; \mu, \sigma^2)$ maksimum v $\widehat{(\mu, \sigma^2)} = (\bar{x}, \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2})$, če $\sum_{i=1}^n (x_i - \bar{x})^2 \neq 0$

Če je $\sum_{i=1}^n (x_i - \bar{x})^2 = 0$, L ni omejena. To je $\iff x_1 = x_2 = x_3 = \dots = x_n$

To nas ne skrbi, ker je dogodek $\{x_1 = x_2 = \dots = x_n\}$ neverjeten ($P(x_1 = x_2) = 0$) (pri kateremkoli $\theta = (\mu, \sigma^2)$)

DEFINICNA

Funkcija $\tilde{f}: D_{\tilde{f}} \rightarrow \mathbb{R}$ je cenička največjega verjetja (cuv), če velja $P(x_1, \dots, x_n \in D_{\tilde{f}}) = 1$ za vsa in $x_1, \dots, x_n \stackrel{\text{NEP}}{\sim} f(\cdot; \theta)$

Za $\theta = (x_1, \dots, x_n) \in D_{\tilde{f}}$ velja $L(x; \tilde{f}(x)) = \max_{\theta \in \mathbb{R}^r} L(x; \theta)$

(Tu privzamemo, da je L mogoče smiselnega razširjeni na \mathbb{R}^r)

Op: v primeru da nimaš samo enega parametra, si pomagaj z Hessegovo matriko da poiščes max

Ker je ln strogo narasločajoča funkcija je \tilde{f} ocena za θ po MNV $\iff \ln L$ ima v \tilde{f} maksimum

$$(L = \prod_{i=1}^n f(x_i; \theta), \ln L = \sum_{i=1}^n \ln f(x_i; \theta))$$

Tipično radi obravnavamo $\ln L$. V bolj pomembnih aplikacijah je L (dovoljkrat) zvezno differencibilna v $\theta \in \mathbb{R}^r$ odp C \mathbb{R}^r .

Ehači: $\frac{\partial(\ln L)}{\partial \theta} = 0$ pravimo LOGARITEMSKA ENAČBA VERJETJA.

$$= EV$$

REPARAMETRIZACIJA

Dani model lahko parametriziramo na različne načine. Če je $\{\tilde{f}(\cdot; \tilde{\theta}) \mid \tilde{\theta} \in \tilde{\Theta}\}$ alternativna parametrizacija, obstaja bijekcija $\tilde{\Theta} \leftrightarrow \Theta$.

Sledi (...), da sta cenički \tilde{f} in f povezani preko iste bijekcije.

DEFINICNA

Naj bo $\Theta^{***} \subset \mathbb{R}^r$ in naj bo $\tilde{\theta}$ CMV za θ . Če je $g: \mathbb{R}^r \rightarrow \mathbb{R}^r$ ($n \leq r$) Borelova funkcija, pravimo, da je $g(\tilde{\theta})$ CUV za $g(\theta)$

2. GLED

Recimo, da nas v NEP-normalnem modelu zanima $E(x^4)$

$$\text{izracunamo } E(x^4) = E((x-\mu+\mu)^4)$$

$$\begin{aligned} &= E\left(\sigma^2 \left[\frac{(x-\mu)}{\sigma}\right]^3 + 4(x-\mu)^3\mu + 6(x-\mu)^2\mu^2 + 4(x-\mu)\mu^3 + \mu^4\right) \\ &= \sigma^4 E\left((X_i)^4\right) + 0 + 6\mu^2\sigma^2 + 0 + \mu^4 \\ &= \sigma^4 (D(X_i^4) + E(X_i^2)^2) + 6\mu^2\sigma^2 + \mu^4 \\ &= 3\sigma^4 + 6\mu^2\sigma^2 + \mu^4 = g(\mu, \sigma^2) \end{aligned}$$

$$\Rightarrow \text{cnu za } E(x^4) \text{ v NEP-normalnem modelu je } 3 \cdot \left[\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right]^2 + 6\bar{x}^2 \cdot \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 + \bar{x}^4$$

4. Poseben primer definicije je: za $\mathbf{v} = (v_1, \dots, v_n)$ utememo $\hat{v}_n = (\hat{v}_i)_i$ (tu je $\hat{v} = \text{proj}_{\mathbf{v}}$)

3. ZREK (o doslednosti CNUV)

Prizemimo, da so gostote (...) $f(\cdot; \mathbf{v})$ dvakrat zvezna diferencibilne v $\mathbf{v} \in \mathbb{R}^n$, da je množica $\{x \mid f(x; \mathbf{v}) > 0\}$ neodvisna od \mathbf{v} in da veljajo se nekateri drugi (blagi) regularnostni prizetki; na gostote (...) $f(\cdot; \mathbf{v})$

če imajo enačbe verjetja (EV) enolične rešitve za vsa dvojji velika števila n , potem njihove rešitve tvorijo dosledno zaporedje cenik za \mathbf{v} .

\curvearrowleft ki je upravil nekoga na ustrem

3 INTERVALSKO OCENJEVANJE

↳ Privzemo, da v nekem modelu ocenjujemo $E(x) = \mu$. Imamo „najboljšo“ nepristransko cenilko \bar{x} . Točkovno oceno \bar{x} za μ želimo „razsiriti“ do intervalске ocene, npr. $[\bar{x} - \text{nekaj}, \bar{x} + \text{nekaj}]$, z željo, da bi dobili verjetnostno zagotovilo, da tak interval ustreže μ .

$$\xleftarrow{\mu} [\underline{\epsilon}, \overline{\epsilon}] \xrightarrow{\mu}$$

Sporazumno se na neenakost čebisjeva: $P(|\bar{x} - \mu| > \epsilon) \leq \frac{D(x)}{\epsilon^2} = \frac{\sigma^2}{n\epsilon^2}$

Preboljkujmo: $P([\bar{x} - \epsilon, \bar{x} + \epsilon] \ni \mu) \geq 1 - \alpha$

Recimo, da želimo, da naša intervalská ocena ustreže μ z verjetnostjo $\geq 1-\alpha$, kjer je α majhno število.

$$\text{Zahlujmo } \frac{\sigma^2}{n\epsilon^2} = \alpha \iff \epsilon = \sqrt{\frac{\sigma^2}{n\alpha}} = \frac{1}{\sqrt{n}} \cdot \frac{\sigma}{\sqrt{\alpha}}$$

$$\text{Sledi } P\left(\bar{x} - \frac{1}{\sqrt{n}} \frac{\sigma}{\sqrt{\alpha}}, \bar{x} + \frac{1}{\sqrt{n}} \frac{\sigma}{\sqrt{\alpha}}\right) \ni \mu \geq 1 - \alpha$$

9.5

DEFINICIJA

Privzemo model F in naj bo $\alpha \in (0, 1)$ (majhno) in $n \in \mathbb{N}$ dani števili interval zaupanja z karakteristiko c za vzorec

velikosti n in stopnja zaupanja $1-\alpha$ je par preslikav $L, U: \mathbb{R}^n \rightarrow \mathbb{R}$ ($L \subseteq U$ poravd), ki zadajoča zahteve

$$P([L(x_1, \dots, x_n), U(x_1, \dots, x_n)]) \ni c(F) \geq 1 - \alpha$$

za uslov $F \in \mathcal{F}$ in vsake vzorec $x_1, \dots, x_n \stackrel{\text{nef}}{\sim} F$

↳ Zgoraj smo iz neenakosti Čebisjeva izpeljali interval zaupanja za $c(x) = E(x)$: $[\bar{x} - \frac{1}{\sqrt{n}} \frac{\sigma}{\sqrt{\alpha}}, \bar{x} + \frac{1}{\sqrt{n}} \frac{\sigma}{\sqrt{\alpha}}]$

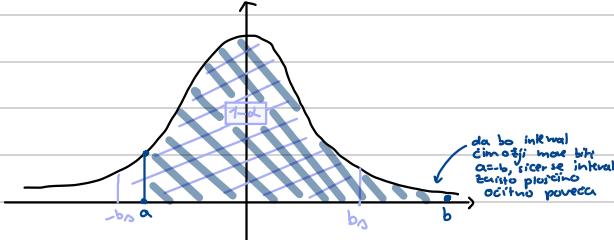
v poljubnem modelu z znano disperzijo

INTERVALI ZAUPANJA V NORMALNIH MODELIH

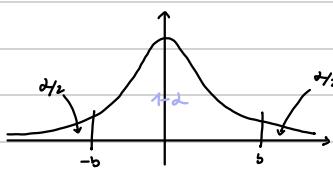
① Iz za μ za vzorec $X_1, \dots, X_n \stackrel{\text{NEP}}{\sim} N(\mu, \sigma^2)$ pri znanem σ^2

porazdelitev neodvisna od μ ! Vemo $\frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \sim N(0, 1)$. Če sta $a < b$ takci števili, da je zanje $P(N(0, 1) \in [a, b]) = \Phi(b) - \Phi(a) = 1-\alpha$, velja $P(a \leq \frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \leq b) = 1-\alpha$
 $\int_a^b f_{N(0,1)}(t) dt$
Prepisimo $\{a \leq \frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \leq b\} = \{\bar{X} - b \cdot \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + a \cdot \frac{\sigma}{\sqrt{n}}\}$
Sledi $P([\bar{X} - b \cdot \frac{\sigma}{\sqrt{n}}, \bar{X} + a \cdot \frac{\sigma}{\sqrt{n}}] \ni \mu) = 1-\alpha$, torej imamo interval zaupanja za μ .

Imamo jih toliko, kot je parov $a < b$, ki zadostijo zgornji izraz:



Takih parov je neskončno mnogo: za katerikoli a , za katerega je $P(N(0,1) \leq a) < \alpha$, obstaja zahtevani b . Izbrali bi tisti par, pri katerem je intervalna ocena najbolj informativna, torej "najročjega". Širina zagornjega intervala je $(b-a) \cdot \frac{\sigma}{\sqrt{n}}$. Zaradi simetričnosti standardne normalne porazdelitve je $b-a$ minimalna pri $-a=b=\Phi^{-1}(1-\alpha/2)$



Dobimo standardni izraz: $[\bar{X} - z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}]$
 \downarrow
majhen z

↳ ZGLED: Primerjava z izrazom neenakosti: Čebisova: za $\alpha=0,05$ je $\frac{1}{\sqrt{2}} \doteq 4,4$, $z_{\alpha/2} = 1,96$

KAJ PA V PRIMERU NEZNANE σ^2 ? σ^2 ocenimo npr. s $S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$

4) IZREK (Student-Fisher)

Naj bodo $x_1, x_2, \dots, x_n \stackrel{\text{NEP}}{\sim} N(\mu, \sigma^2)$. Tedaj sta \bar{x} in S^2 neodvisni in $\sum_{i=1}^n \left(\frac{x_i - \bar{x}}{\sigma} \right)^2 = \frac{n-1}{\sigma^2} S^2$ ima porazdelitev $\chi^2_{n-1} = \text{Gama}\left(\frac{n-1}{2}, \frac{1}{2}\right)$

5) POSLEDICA

Slučajna spremenljivka $t = \frac{\bar{x} - \mu}{S/\sqrt{n}}$ ima porazdelitev, ki je neodvisna od μ in σ^2

DOKAZ POSLEDICE

$$t = \frac{\frac{\bar{x} - \mu}{\sigma/\sqrt{n}}}{\sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{(n-1)}} / (\sigma/\sqrt{n})} \sim N(0, 1) \rightarrow \text{neodvisno od } \mu$$

Torej bo funkcija neodvisnih, tuji neodvisna od μ in σ^2 ??

$\chi^2_{n-1} \rightarrow \text{neodvisno od } \sigma^2$

6) DEFINICIJA

Naj bosta Z in H neodvisni SS., $Z \sim N(0, 1)$, $H \sim \chi^2_h = \text{Gama}\left(\frac{h}{2}, \frac{1}{2}\right)$. Tedaj ima:

$$t = \frac{Z}{\sqrt{H/h}}$$

studentovo porazdelitev s h prostostnimi stopnjami, označimo jo t_h .

Ocitno je t_h porazdelitev, ki lahko zavzame katerokoli realno število. Poleg tega je t_h simetrična ($-t_h \sim t_h$). To sledi iz simetričnosti porazdelitve $N(0, 1)$.

DN: Iz gostote $N(0, 1)$ in χ^2_h izpeljite gostoto t_h .

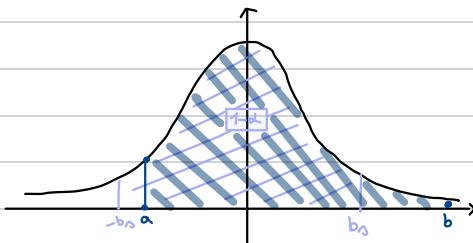
② Iz za μ za vzorec $x_1, \dots, x_n \stackrel{\text{NEP}}{\sim} N(\mu, \sigma^2)$ pri neznani σ^2

Vemo $\frac{\bar{x} - \mu}{S/\sqrt{n}} \sim t_{n-1}$. Če sta $a < b$ takci števili, da je zanje $P(t_{n-1} \in [a, b]) = F_{t_{n-1}}(b) - F_{t_{n-1}}(a) = 1-\alpha$, velja $P(a \leq \frac{\bar{x} - \mu}{S/\sqrt{n}} \leq b) = 1-\alpha$

$$\text{Prepisimo } \{a \leq \frac{\bar{x} - \mu}{S/\sqrt{n}} \leq b\} = \{\bar{x} - b \cdot \frac{S}{\sqrt{n}} \leq \mu \leq \bar{x} - a \cdot \frac{S}{\sqrt{n}}\}$$

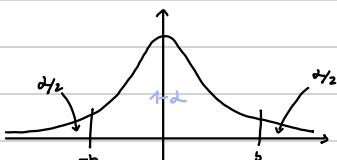
Sledi $P\left(\underbrace{[\bar{x} - b \cdot \frac{S}{\sqrt{n}}, \bar{x} - a \cdot \frac{S}{\sqrt{n}}]}_{L(x_1, \dots, x_n)} \ni \mu\right) = 1-\alpha$, torej imamo interval zaupanja za μ .

Imamo jih toliko, kot je parov $a < b$, ki zadostujejo zgornji izraz:



Takih parov je neskončno mnogo: za katenekoli a , za katerega je $P(t_{n-1} \in a) < \alpha$, obstaja zahtevani b . Izbrali bi tisti par, pri katem je intervalska ocena najbolj informativna, torej "najročjega". Sirina zgornjega intervala je $(b-a) \cdot \frac{S}{\sqrt{n}}$.

Ta sirina je SS. Zaradi simetričnosti studentove porazdelitve je $b-a$ minimalna pri $-a=b=F_{t_{n-1}, \alpha/2}\left(\frac{1-\alpha}{2}\right)$



Dobimo standardni 12: $\left[\bar{x} - t_{n-1, \alpha/2} \cdot \frac{S}{\sqrt{n}}, \bar{x} + t_{n-1, \alpha/2} \cdot \frac{S}{\sqrt{n}} \right]$

DOKAZ (STUDENT - FISHER)

Pišimo $Y_i = \frac{X_i - \bar{X}}{\sigma}$. Sveda $Y_i \sim_{\text{NEP}} N(0, 1)$. Zaradi linearnosti je $Y_i - \bar{Y} = \frac{X_i - \bar{X}}{\sigma} \quad (\Leftarrow \bar{Y} = \frac{\bar{X} - \bar{X}}{\sigma})$

Dovolj je dokazati, da sta \bar{Y} in $\sum_{i=1}^n (Y_i - \bar{Y})^2$ neodvisni in da je $\sum_{i=1}^n (Y_i - \bar{Y})^2 \sim \chi_{n-1}^2$. Izrazimo

$$Y_i - \bar{Y} = \frac{1}{n} Y_1 - \frac{1}{n} Y_2 - \dots + (1 - \frac{1}{n}) Y_i - \dots - \frac{1}{n} Y_n$$

Vpeljemo matriko $A_{ij} = -\frac{1}{n} + \begin{cases} 1 & i=j \\ \frac{1}{n} & i \neq j \end{cases}$ oziroma $A_{ij} = I - \frac{1}{n} \begin{bmatrix} 1 & \dots & 1 \\ \vdots & \ddots & \vdots \\ 1 & \dots & 1 \end{bmatrix} = \begin{bmatrix} 1-\frac{1}{n} & -\frac{1}{n} & -\frac{1}{n} & \dots & -\frac{1}{n} \\ -\frac{1}{n} & 1-\frac{1}{n} & -\frac{1}{n} & \dots & -\frac{1}{n} \\ -\frac{1}{n} & -\frac{1}{n} & 1-\frac{1}{n} & \dots & -\frac{1}{n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ -\frac{1}{n} & -\frac{1}{n} & -\frac{1}{n} & \dots & 1-\frac{1}{n} \end{bmatrix}$

Očitno je $\sum_{i=1}^n (Y_i - \bar{Y})^2 = \|A \cdot \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}\|_2^2$. Ker je A simetrična imata realne lastne vrednosti in jo je mogoče diagonalizirati (nach IR) v ON lastni bazi.

$$A = Q \cdot D \cdot Q^T$$

kjer je $D = \begin{bmatrix} \lambda_1 & & & \\ & \ddots & & \\ & & \lambda_n & \\ & & & \ddots & \lambda_m \end{bmatrix}$ matrika lastnih vrednosti, Q pa ortogonalna matrika pridruženih lastnih vektorjev ($Q^T Q = Q Q^T = I$)

lastne vrednosti: $A \cdot \lambda I = I - \frac{1}{n} \begin{bmatrix} 1 & \dots & 1 \\ \vdots & \ddots & \vdots \\ 1 & \dots & 1 \end{bmatrix} - \lambda I = -\frac{1}{n} \begin{bmatrix} 1 & \dots & 1 \\ \vdots & \ddots & \vdots \\ 1 & \dots & 1 \end{bmatrix} - (\lambda - 1) I$

$$\underbrace{\det(A - \lambda I)}_{P_A(\lambda)} = (-1)^n \cdot \underbrace{\det(B - (\lambda - 1)I)}_{P_B(\lambda)} \quad \text{kjer je } B = \frac{1}{n} \begin{bmatrix} 1 & \dots & 1 \\ \vdots & \ddots & \vdots \\ 1 & \dots & 1 \end{bmatrix}$$

kompleksni polnom $\hookrightarrow \text{rang } B = 1 \rightarrow \text{rang ker}(B) = n-1 \rightarrow \text{lastna vr. } 0 \text{ je } \frac{n-1}{n-1} \text{ kratna}$

Očitno je $\mu = 0$ lastna vr. stopnje $(n-1)$ za B

Dalje je $B \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix}$, torej imamo je eno lastno vrednost $\lambda = 1$ s pripadajočim lastnim vektorjem $\begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix}$

Sledi $D = \begin{bmatrix} 1 & & & \\ & \ddots & & \\ & & 1 & \\ & & & 0 \end{bmatrix}$ in $A \cdot \begin{bmatrix} \sqrt{\lambda_1} \\ \vdots \\ \sqrt{\lambda_n} \end{bmatrix} = 0$, torej $Q = \begin{bmatrix} & & \sqrt{\lambda_1} \\ & \ddots & \vdots \\ & & \sqrt{\lambda_n} \end{bmatrix}$

n-razrešena standardska normalna

vezavni vektorji

$$\left[\begin{aligned} f(y_1, \dots, y_n) &= \prod_{i=1}^n \left[(2\pi)^{-\frac{1}{2}} e^{-\frac{1}{2} y_i^2} \right] \\ &= (2\pi)^{-\frac{n}{2}} e^{-\frac{1}{2} \sum_{i=1}^n y_i^2} \\ &= (2\pi)^{-\frac{n}{2}} e^{-\frac{1}{2} \langle y, y \rangle} \\ &= (2\pi)^{-\frac{n}{2}} e^{-\frac{1}{2} \langle I(y=0), y=0 \rangle} \end{aligned} \right]$$

velja $y = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} \sim N\left(\begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}, I_{n,n}\right)$

n-razrešena standardska normalna

matrica skalarne proizvod

$$\|AY\|^2 = \langle AY, AY \rangle = \langle QDQ^T y, QDQ^T y \rangle = \langle DQ^T y, DQ^T y \rangle = \langle D(Q^T y), DQ^T y \rangle = \|D(Q^T y)\|_2^2 = \sum_{i=1}^m z_i^2$$

ortogonalna matrika omogoča skalarne proizvode

$Q^T Q = Q Q^T = I$

$D^2 = D$

kjer $Z = Q^T y \sim N\left(\begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}, Q^T I \cdot (Q^T)^T\right)$

$$\|Q^T 0\|$$

$$\|I\|$$

Sledi $Z_i \stackrel{\text{NEP}}{\sim} N(0, 1)$ in zato $\sum_{i=1}^m z_i^2 \sim \chi_{n-1}^2$

Poleg tega sta $\sum_{i=1}^n (y_i - \bar{Y})^2$ in Z_n neodvisni. Po definiciji je $Z_n = \frac{1}{\sqrt{n}} (y_1 + \dots + y_n) = \sqrt{n} \bar{Y}$

saj so lin. kombinacije različnih lastnih vektorjev, ki pa so neodvisni

simetrične matrice lahko diagonaliziramo (Q je matrica ONS lastnih vektorjev)

③ Iz za σ^2 pri znani μ v NEP-normalnem modelu

Za $X_1, X_2, \dots, X_n \stackrel{\text{NEP}}{\sim} N(\mu, \sigma^2)$ velja

$$\sum_{i=1}^n \left(\frac{(X_i - \mu)}{\sigma} \right)^2 \sim \chi^2_n$$

Naj bosta $a, b \in (0, \infty)$ taki st., da $a < b$ in: $P(X_n^2 \in [a, b]) = F_{\chi^2_n}(b) - F_{\chi^2_n}(a) = 1-\alpha$

Tedaj je $P(a \leq \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 \leq b) = 1-\alpha$

$$P\left(\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 \leq \sigma^2 \leq \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2\right)$$

To pomeni, da je $\left[\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2, \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2\right]$ iz za σ^2 za vzorec velikosti n stopnje zaupanja $1-\alpha$.

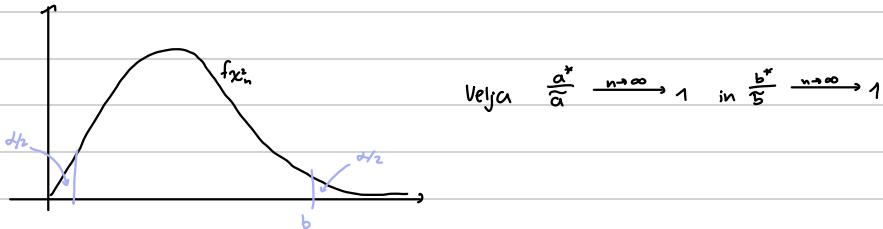
zanimajo nas, katera izbira para (a, b) je optimalna v smislu širine iz. Ta je $(\frac{1}{\sigma^2} - \frac{1}{\sigma^2}) \sum_{i=1}^n (X_i - \mu)^2$. To je s.s.!

če sta a^* in b^* taki števili, da je $\frac{1}{\sigma^2} - \frac{1}{\sigma^2}$ minimalna pri zvezri $P(X_n^2 \in [a, b]) = 1-\alpha$, imata pridruženi interval zaupanja

ENAKOMERNO najmanjšo širino:

$$V(X_1, \dots, X_n): \left(\frac{1}{\sigma^2} - \frac{1}{\sigma^2} \right) \sum_{i=1}^n (X_i - \mu)^2 \leq \left(\frac{1}{\sigma^2} - \frac{1}{\sigma^2} \right) \sum_{i=1}^n (X_i - \mu)^2$$

Izkazuje se, da je ta minimizacijski problem ($\min(\frac{1}{\sigma^2} - \frac{1}{\sigma^2})$ z vezjo $\int f_{\chi^2_n} du = 1-\alpha$) racunsko intenziven, zato v praksi tipično vzamemo $\tilde{a} = F_{\chi^2_n}^{-1}(\alpha/2)$ $\tilde{b} = F_{\chi^2_n}^{-1}(1-\alpha/2)$ ENAKOREPA REBINA



④ Iz za σ^2 pri neznani μ v NEP-normalnem modelu

Za $X_1, X_2, \dots, X_n \stackrel{\text{NEP}}{\sim} N(\mu, \sigma^2)$ velja

$$\sum_{i=1}^n \left(\frac{(X_i - \bar{x})}{\sigma} \right)^2 \sim \chi^2_{n-1}$$

je student-Fisherjevga zakona

Naj bosta $a, b \in (0, \infty)$ taki st., da $a < b$ in: $P(X_{n-1}^2 \in [a, b]) = F_{\chi^2_{n-1}}(b) - F_{\chi^2_{n-1}}(a) = 1-\alpha$

Tedaj je $P(a \leq \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{x})^2 \leq b) = 1-\alpha$

$$P\left(\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{x})^2 \leq \sigma^2 \leq \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{x})^2\right)$$

To pomeni, da je $\left[\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{x})^2, \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{x})^2\right]$ iz za σ^2 za vzorec velikosti n stopnje zaupanja $1-\alpha$.

zanimajo nas, katera izbira para (a, b) je optimalna v smislu širine iz. Ta je $(\frac{1}{\sigma^2} - \frac{1}{\sigma^2}) \sum_{i=1}^n (X_i - \bar{x})^2$. To je s.s.!

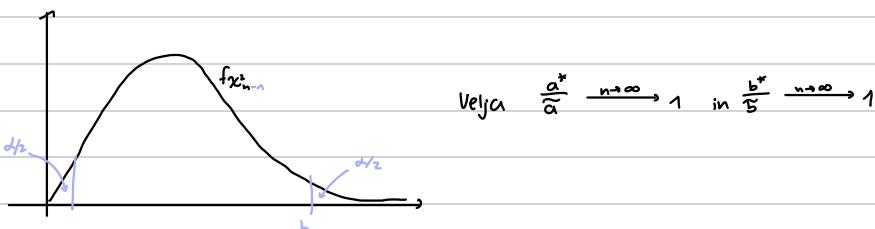
če sta a^* in b^* taki števili, da je $\frac{1}{\sigma^2} - \frac{1}{\sigma^2}$ minimalna pri zvezri $P(X_{n-1}^2 \in [a, b]) = 1-\alpha$, imata pridruženi interval zaupanja

ENAKOMERNO najmanjšo širino:

$$V(X_1, \dots, X_n): \left(\frac{1}{\sigma^2} - \frac{1}{\sigma^2} \right) \sum_{i=1}^n (X_i - \bar{x})^2 \leq \left(\frac{1}{\sigma^2} - \frac{1}{\sigma^2} \right) \sum_{i=1}^n (X_i - \bar{x})^2$$

Izkazuje se, da je ta minimizacijski problem ($\min(\frac{1}{\sigma^2} - \frac{1}{\sigma^2})$ z vezjo $\int f_{\chi^2_{n-1}} du = 1-\alpha$) racunsko intenziven, zato v praksi tipično

vzamemo $\tilde{a} = F_{\chi^2_{n-1}}^{-1}(\alpha/2)$ $\tilde{b} = F_{\chi^2_{n-1}}^{-1}(1-\alpha/2)$ ENAKOREPA REBINA



PREIZKUŠANJE DOMNEV

UVOD

Recimo, da obstajata dva tipa evrskih kozancev: "pošten" s $p_0 = \frac{1}{2}$ in "nepošten" s $p_0 = \frac{3}{5}$. Za konanec v roki bi na podlagi 10 (neodvisnih slučajnih) metov radi bodisi podprtji domnevo "poštenosti" ($p=p_0$) bodisi podprtji domnevo "nepoštenosti" ($p=p_1$). Naaj bo k stevilo enic

| k | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 |
|-----------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| oddelenje | p_0 | p_0 | p_0 | p_0 | p_0 | p_1 | p_0 | p_1 | p_0 | p_1 |

podpremo p_0 podpremo p_1

koj gre lahko narobe?

① Pošten konanec lahko razglasimo za nepoštenega

· Verjetnost te zmotje je $P(B(10, \frac{1}{2}) > 5) = 0,38$

· Če bi podprtli po do vključno 8, bi imeli verjetnost zmotje $P(B(10, \frac{1}{2}) > 8) = 0,01$

② Nepošten konanec "razglasimo" za poštnega

· Verjetnost te zmotje je $P(B(10, \frac{3}{5}) \leq 8) = 0,95$

Slošneje bi $p = p_0$ podprtli za $k \leq C$, $p = p_1$ za $k > C$ za neko konstanto C

| k | 0 | 1 | ... | C | $C+1$ | ... | 9 | 10 |
|-----------|-------|-------|-----|-------|-------|-----|-------|-------|
| oddelenje | p_0 | p_0 | ... | p_0 | p_1 | ... | p_0 | p_1 |

podpremo p_0 podpremo p_1

Verjetnost napake 1. vrste: $P(B(10, \frac{1}{2}) > C)$

Verjetnost napake 2. vrste: $P(B(10, \frac{3}{5}) \leq C)$

Vidimo, da ne moremo konstruirati verjetnost obeh napak.

SPOŠNO O PREIZKUSANJU DOMNEV

Prizemimo model F in naj bo $X = (X_1, \dots, X_n)$ slučajni vzorec z $X_i \stackrel{\text{iid}}{\sim} F$ za neki $F \in \mathcal{F}$

STATISTIČNA DOMNEVA je izjava o PORAZDELITVI proučevanja vektorja X , ki je bodisi pravilna bodisi nеправилна, če je porazdelitev znana.

→ ZGLEDI DOMNEV

· $E(X) \leq 50$

$\mathbb{H} = \mathbb{R} \times (0, \infty) \cup \{\mu, \sigma^2 \mid \mu \in \mathbb{R}, \sigma^2 \in (0, \infty)\}$, $H = (-\infty, 50] \times (0, \infty)$

· $P(X \leq 7) = \frac{1}{2}$

$\{(\mu, \sigma^2) \mid P(N(\mu, \sigma^2) \leq 7) = \frac{1}{2}\}$

· $\text{Var}(X) > 42$

$H = \mathbb{R} \times (42, \infty)$

↳ Posledično lahko domnevo enacimo s primerno podmnožico množice \mathcal{F} . Tipično jo oznamimo \mathcal{H} . (tiste porazdelitve, za katere je izjava pravilna)

↳ Če je model parametriziran $\mathcal{F} \leftrightarrow \mathbb{H}$, domnevo enacimo s primerno podmnožico $H \subset \mathbb{H}$

"Domnevi H je pridružena „alternativna domneva“ A , oziroma domnevi H je pridružena „alternativna domneva“

$A \subset H$. Tipično je $A = H^c$ oziroma $A = H^c$, včasih pa nas zanimajo $A \subsetneq H^c$

• V uvodnem zgledu $F \leftrightarrow \{1_2, 3_3\}; H = \{1_2\}, A = \{3_3\}$

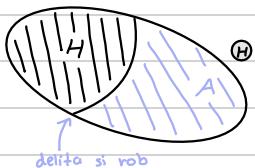
DEFINICIJA

Priekus domneve H je odločitveno pravilo, po katerem na podlagi realizacije slučajnega vzorca dane velikosti bodoši podpremo H ali održimo H .

↳ Kaj je lahko pri dane m odločitvenem pravilu narobe?

| dejansko stanje odločitve | drži H | drži A |
|------------------------------|--------------------|--------------------|
| podpremo H | ✓ | NAPAKA 2. vrste |
| ne zavrnemo H | | |
| podpremo A | NAPAKA 1. vrste | ✓ |
| zavrnemo H | | |

↳ Želite bi majhni verjetnosti napak. Izkaže se, da ne moremo kontroličati verjetnosti napak dveh vrst. (če je prostor parametrov H zvezen in je H v njem lepa podmnogica, sta supremuma verjetnosti obih vrst napak komplementarna: njuna vsota = 1)



↳ V praksi se moramo za to odločiti (ali pa se za nas odloči „nadzorno telo“) katera od napak je pomembnejša (po potrebi zamenjamo ulogi H in A) in njen verjetnost polem omejimo. Recemo ji napaka 1. vrste (TYPE 1. ERROR)

Pravimo, da ima priekus stopnje značilnosti α (stopnjo tveganja α), če je supremum verjetnosti napak 1. vrste $\leq \alpha$
(v praksi so tipične izbire za α : 0.05, 0.1, 0.01)

α je velikost priekusa

Preostali napaki pravimo napaka 2. vrste

KOMENTAR

$P(\text{podprem } A | \text{drži } H) \leq \alpha$. Če priekus podpre A pravimo, da smo A „statistično dokazali“

$P(\text{podprem } H | \text{drži } A)$ je lahko tudi $1-\alpha$

↳ Jezik: Napaka 1. vrste se zgoodi, če zavrnemo H , v resnici pa H drži

PREIZKUŠANJE STANDARDNIH DOMNEV V BERNOULLIJEVIH MODELIH

↳ To so domneve: $\cdot p \leq p_0$ ($H = (0, \infty)$, $A = (p_0, \infty)$)

$\cdot p \geq p_0$ ($H = [p_0, \infty)$, $A = (0, p_0)$)

$\cdot p = p_0$ ($H = \{p_0\}$, $A = (0, \infty) \setminus \{p_0\}$)

① PREIZKUŠANJE $H: p \leq p_0$ proti $A: p > p_0$

Preizkušamo na podlagi preizkusne statistike (za vzorec velikosti n)

$$T = X_1 + \dots + X_n \sim B(n, p)$$

Edina smiselna oblika preizkusa je $\begin{cases} p \leq p_0 \text{ zavrnemo, če je } T \geq c \\ p \leq p_0 \text{ ne zavrnemo, če je } T \leq c \end{cases}$ Ijer moramo smiselno določiti c

• Verjetnost 1. napake

$$P(T \geq c | p \leq p_0) = P(B(n, p) \geq c | p \leq p_0) = \sum_{i=c}^n \binom{n}{i} p^i (1-p)^{n-i}$$

To je funkcija definirana na $(0, p_0]$ in je naraščajoča in doseže maksimum v p_0 .

Preiskar ima st. značilnosti $\lambda \Leftrightarrow P(B(n, p_0) \geq c) \leq \lambda$

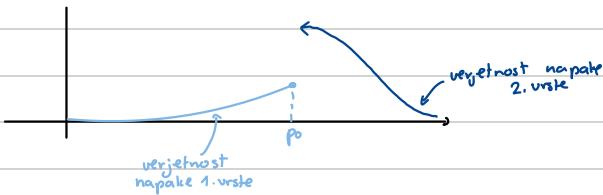
DN: dokazati, da je res naraščajoča

• Verjetnost napake 2. vrste

$$P(T \leq c | p > p_0) = \sum_{i=0}^{c-1} \binom{n}{i} p^i (1-p)^{n-i}$$

funkcija, definirana na $(p_0, 1)$. je padajoča in njen supremum je dosežen, ko je $p = p_0$.

Ta supremum znaslo $P(B(n, p_0) \leq c)$



• vidimo $P(B(n, p_0) > c) + P(B(n, p_0) \leq c) = 1$, torej sta supremuma komplementarna

$$\cdot 23.5 \quad P(B(n, p_0) > c+1) \leq \underbrace{P(B(n, p_0) > c)}_{\lambda} \leq \lambda$$

\Rightarrow množica tistih c , ki zadostajo neenakosti, je oblika $\{c_0, c_0+1, \dots\}$

PREIZKUŠANJE V NORMALNIH MODELIH

① PREIZKUŠANJE $\mu \leq \mu_0$ PROTI $\mu > \mu_0$

Intuitivno je jasno, da bi $\mu \leq \mu_0$ zavrnili, če $\bar{x} > c$.

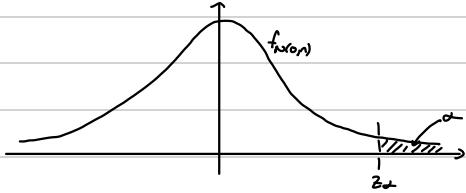
a) Disperzija σ^2 je znana (konstantna)

$$P(\bar{x} > c) = P\left(\frac{\bar{x}-\mu_0}{\sigma/\sqrt{n}} > \frac{c-\mu_0}{\sigma/\sqrt{n}}\right) = 1 - \Phi\left(\frac{c-\mu_0}{\sigma/\sqrt{n}}\right)$$

stoji naraščajoča
povečava
k.p.f. od $N(0,1)$

To je naraščajoča funkcija μ . Verjetnost napake 1. vrste je zato maksimalna pri μ_0

Za c izberemo rešitev enačbe $1 - \Phi\left(\frac{c-\mu_0}{\sigma/\sqrt{n}}\right) = \alpha$. To pomeni $\frac{c-\mu_0}{\sigma/\sqrt{n}} = z_\alpha$ oziroma $c = \mu_0 + z_\alpha \cdot \frac{\sigma}{\sqrt{n}}$



Zavrnitveni dogodek je $\{\bar{x} > c\} = \{\bar{x} > \mu_0 + z_\alpha \cdot \frac{\sigma}{\sqrt{n}}\} = \left\{\frac{\bar{x}-\mu_0}{\sigma/\sqrt{n}} > z_\alpha\right\}$

Torej $\mu \leq \mu_0$ (pri znani σ^2) zavrnemo $\Leftrightarrow \frac{\bar{x}-\mu_0}{\sigma/\sqrt{n}} > z_\alpha$

b) Pri neznanem σ^2 :

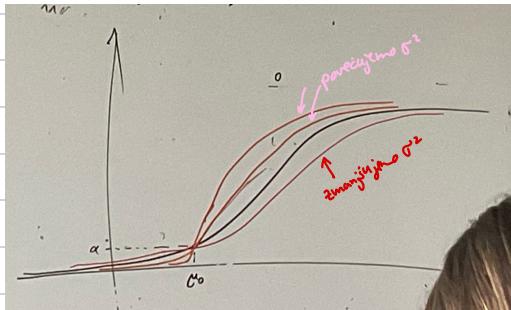
$$\frac{\bar{x}-\mu_0}{\sigma/\sqrt{n}} > D$$

$$\beta: \mathbb{R} \times (0, \infty) \rightarrow [0, 1]$$

$$\beta(\mu_0, \sigma^2) = P\left(\frac{\bar{x}-\mu_0}{\sigma/\sqrt{n}} > D\right)$$

$N(\mu_0, \sigma^2/n)$

$$\beta(\mu_0, \sigma^2) = P(t_{m,1} > D)$$



PROBLEM DVEH VZORCEV

① „PARNA PRIMERJAVA“

Meritvi X_{11}, X_{12} (dve časovni točki) za $1 \leq i \leq n$. Tipično domneve v zvezri $\mu_1 - \mu_2$ prevedemo na domnevne v zvezri s p.v. razlike $X_{11} - X_{12}$

Uporabimo prizluse za pričakovano vrednost "ene" s.s.

② „NEPARNE PRIMERJANE“ oz. problem dveh neodvisnih vzorcev

$X_{11}, 1 \leq i \leq n_1, \text{NEP } N(\mu_1, \sigma_1^2)$

$X_{12}, 1 \leq i \leq n_2, \text{NEP } N(\mu_2, \sigma_2^2)$

Pričazamemo, da sta vektorja (X_{11}, \dots, X_{n_1}) in (X_{12}, \dots, X_{n_2}) neodvisna

$$\text{Prisimo } \bar{X}_1 := \frac{1}{n_1} \sum_{i=1}^{n_1} X_{1i}, \quad \bar{X}_2 := \frac{1}{n_2} \sum_{i=1}^{n_2} X_{1i}$$

$$\text{Var}(\bar{X}_1 - \bar{X}_2) = \text{Var}(\bar{X}_1) + \text{Var}(\bar{X}_2) = \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}$$

neodvisnost

$$\frac{\bar{X}_1 - \bar{X}_2 - D_0}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}} \quad \left. \begin{array}{l} \text{na robu je to standarni} \\ \text{normalka} \end{array} \right.$$

a) Variance σ_1^2 in σ_2^2 sta znani

$$\text{Domnevo } \mu_1 - \mu_2 \leq D_0 \text{ zavremo (pri stopnji enacilnosti } \alpha), \text{ ite} \quad \frac{\bar{X}_1 - \bar{X}_2 - D_0}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \geq z_\alpha$$

$$\mu_1 - \mu_2 \geq D_0$$

$$-1-$$

$$< -z_\alpha$$

$$\mu_1 - \mu_2 = D_0$$

nekaj manjka

↓
naslednja stran
od kaje

Problem dveh naborov(1) "PARNA PRIMERJAVA"

menjtri X_{11}, X_{12} (dve časovi študije) za $1 \leq i \leq n_1$. Tipično domnevate, da je $\mu_1 - \mu_2$ prevedeno na domnevate, da je $\mu_1 - \mu_2$ p.r. razlike $X_{11} - X_{12}$.

Uporabimo preiskuse za prizakovano mrednoto "enote" s.p.

(2) "NEPARNE PRIMERJAVE" oz. problem dveh međudružnih naborov

$X_{11}, 1 \leq i \leq n_1$, NEP $N(\mu_1, b_1^2)$

$X_{12}, 1 \leq i \leq n_2$, NEP $N(\mu_2, b_2^2)$. Priznamemo, da sta velikosti (X_{11}, \dots, X_{n_1}) in (X_{12}, \dots, X_{n_2}) neodvisna.

$$\text{Pišimo } \bar{X}_1 := \frac{1}{n_1} \sum_{i=1}^{n_1} X_{1i}, \quad \bar{X}_2 := \frac{1}{n_2} \sum_{i=1}^{n_2} X_{1i}$$

$$\text{Var}(\bar{X}_1 - \bar{X}_2) = \text{Var}(\bar{X}_1) + \text{Var}(\bar{X}_2) = \frac{b_1^2}{n_1} + \frac{b_2^2}{n_2}$$

$\mu_1 - \mu_2 \leq D_0 \rightarrow$ ohranitev nad veliko premočjo

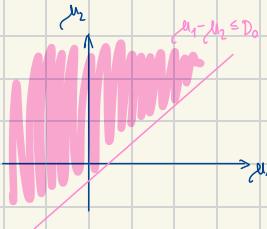
$\mu_1 - \mu_2 = D_0 \rightarrow$ nelo ohranitev ipo nizke standardne napakal.

(a) Varianci b_1^2 in b_2^2 sta znani

Domnevo: $\mu_1 - \mu_2 \leq D_0$ zavrnemo (pri stopnji značilnosti α), če

$\mu_1 - \mu_2 \geq D_0$ zavrnemo (pri stopnji značilnosti α), če

$\mu_1 - \mu_2 = D_0$ zavrnemo če

(b) Varianci netrnni

(i) varianci netrnni jin REAČINI

(ii) varianci netrnni in ENAKI (homoskedastični primer)

$$X_{11} \stackrel{\text{NEP}}{\sim} N(\mu_1, b^2), \quad X_{12} \stackrel{\text{NEP}}{\sim} N(\mu_2, b^2)$$

$$\bar{X}_1 - \bar{X}_2 - D_0$$

$$\sqrt{\frac{1}{n_1+n_2-2} \left(\sum_{i=1}^{n_1} (X_{1i} - \bar{X}_1)^2 + \sum_{i=1}^{n_2} (X_{1i} - \bar{X}_2)^2 \right) \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}$$

zavrnemo domneve, če $| \dots | > t_{n_1+n_2-2} ; \alpha$

$< t_{n_1+n_2-2} ; \alpha$

$$| \dots | > t_{n_1+n_2-2} ; \alpha/2$$

$\approx S^2$

PREIZKUŠANJE NA PODLAGI RAZMERJA VERJETJI

↳ Razmerje verjetij (za dano domnevo H_0) je statistika, ki jo lahko v splošnem uporabimo kot prizkushno statistiko za preizkušanje H_0 .

↳ Privzemimo parametričen model F s prostorom parametrov $\Theta \subseteq \mathbb{R}^d$ in naj bo $H_0 \subseteq H \subseteq \Theta$ domneva. Razmerje verjetij za H_0 za upore velikosti nje funkcija: $\lambda: \mathbb{R}^n \rightarrow [0, 1]$

$$\lambda(x_1, \dots, x_n) = \lambda(x) = \frac{\sup_{\theta \in H_0} \{L(x, \theta) \mid \theta \in H_0\}}{\sup_{\theta \in H} \{L(x, \theta) \mid \theta \in H\}}$$

soj izmena je podmožice

kjer je $L(x; \theta) = f(x_1; \theta) \cdots f(x_n; \theta)$

DEFINICIJA: je najlažje opravljeno interpretirati, če primenjamo regularnostne praveteke za L iz razdelka o metodi največjega verjetja.

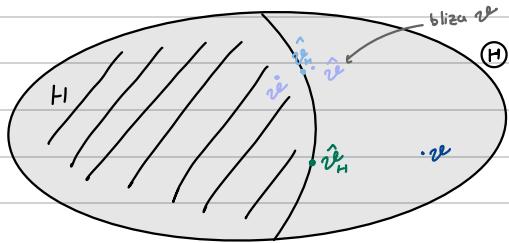
$$\forall \theta: P(x=x) = 0$$

se vedo

KOMENTAR: konkretno privzemimo, da je $S = \{x \in \mathbb{R}^n \mid L(x; \theta) > 0\}$ neodvisna od θ . Tedaj lahko razumemo, da je L definirana na S .

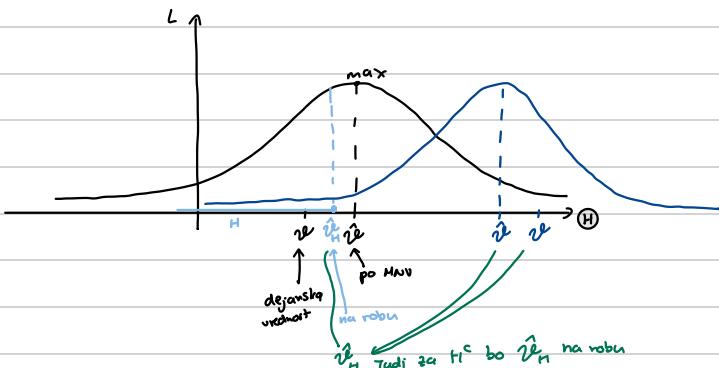
Seveda je $\lambda(x) = \frac{\sup_{\theta \in H_0} \{L(x, \theta) \mid \theta \in H_0\}}{\sup_{\theta \in H} \{L(x, \theta) \mid \theta \in H\}}$, če obstaja CNU že za θ .

Pravimo, da je $\hat{\theta}_H(x)$ "restringirana" ocena po MNV za θ , če velja $\sup_{\theta \in H} L(x, \theta) = L(x, \hat{\theta}_H(x))$



* Realizacija (x_1, \dots, x_n) je prisila iz porazdelitve, ki jih ustreza $\theta \in H$
 $[\theta \text{ ga je cenuka za } \theta]$

$\lambda(x)$ bo "velik" "blizu" 1.



* - Realizacija je prisila iz porazdelitve, ki ji ustreza $\theta \in H^c$

Tu bo λ "blizu" 0

IDEJA ZA PREIZKUS:

$$\begin{cases} H_0 \text{ zaurnemo; če je } \lambda < D \\ H_1 \text{ ne zaurnemo; če je } \lambda \geq D \end{cases}$$

rebrasta konstanta

Konstanto D naceloma določimo z zahtevo z zahtevno velikostjo: $\sup_{\theta \in H^c} P(\lambda(x_1, \dots, x_n) \leq D) \leq \alpha$

① Preizkušanje $H_0: \mu = \mu_0$ proti $\mu \neq \mu_0$ v normalnem modelu z neznanjo disperzijo

$$(H_0) = \mathbb{R} \times (0, \infty) \rightarrow (\mu, \sigma^2), H_1 = \{\mu_0\} \times (0, \infty)$$

$$L(x; \mu, \sigma^2) = (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2}$$

$$\text{že vemo: } \widehat{(\mu, \sigma^2)} = (\bar{x}, \frac{1}{n-n} \sum_{i=1}^n (x_i - \bar{x})^2)$$

Za "izčemo maksimum funkcije $\sigma^2 \mapsto L(x; \mu_0, \sigma^2)$ " ene spremenljivke.

Enako kot za funkcijo $\sigma^2 \mapsto L(x; \bar{x}, \sigma^2)$ dobimo, da je maksimum dosežen pri $\hat{\sigma}_H^2 = \frac{1}{n-n} \sum_{i=1}^n (x_i - \mu_0)^2$

Op.: glej zgled pri MNV v normalnem modelu

$$\text{Sledi } \chi(x) = \frac{L(x; \mu_0, \hat{\sigma}_H^2)}{L(x; \hat{\mu}, \hat{\sigma}^2)} = \left(\frac{\hat{\sigma}_H^2}{\hat{\sigma}^2} \right)^{-\frac{n}{2}} = \left(\frac{\sum_{i=1}^n (x_i - \mu_0)^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right)^{-\frac{n}{2}} = \left(\frac{\sum_{i=1}^n (x_i - \bar{x})^2 + \mu(\bar{x} - \mu_0)^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right)^{-\frac{n}{2}} = \left(1 + \frac{n(\bar{x} - \mu_0)^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right)^{-\frac{n}{2}}$$

eliptični del
v $L(x; \mu, \sigma^2)$ se
bo v celoti
potravnal

ko smo $\frac{1}{2} (x_i - \mu)^2$ re
godek minimizirali
velja "pitagorov zakon"

Pogljemo kaj je zavrnitveni pogoj

$$\begin{aligned} \chi(x) < D &\iff 1 + \dots + \frac{\frac{(x_i - \mu_0)^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}{D} > 1 \\ &\Downarrow \text{oddeglemo } 1 \\ &\iff \frac{(x_i - \mu_0)^2}{(\frac{1}{n-n} \sum_{i=1}^n (x_i - \bar{x})^2)/n} > D \quad \text{Torej lahko karimmo} \end{aligned}$$

Konstante D bodo tudi $\in (0, 1)$

$D' > 1$

D' je pozitiven

$$\iff \left| \frac{\bar{x} - \mu_0}{\sqrt{\frac{1}{n-n} \sum_{i=1}^n (x_i - \bar{x})^2 / n}} \right| > c$$

$t \rightarrow$ statistika
 s/\sqrt{n}

Ta preizkus je ekvivalenten „standardnemu“ izrazenu $C = t_{n-1, \alpha/2}$

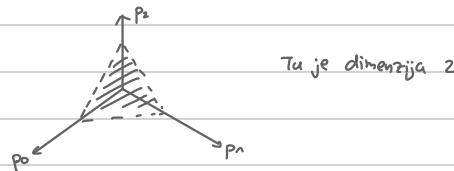
② DN: prepričajte se, da podobno velja za $H_0: \mu \leq \mu_0$ proti $\mu > \mu_0$

③ Prilagoditveni preizkus cisto določene porazdelitve

Vzremimo diskretno porazdelitev na fiksnih vrednostih $\xi_0 < \xi_1 < \dots < \xi_d$, torej $x_1, x_2, \dots, x_n \stackrel{\text{NRP}}{\sim} \begin{pmatrix} \xi_0 & \xi_1 & \dots & \xi_d \\ p_0 & p_1 & \dots & p_d \end{pmatrix}$

Parametrični prostor je $\Delta^d = \{ (p_0, p_1, \dots, p_d) \mid p_j \geq 0, \sum_{j=0}^d p_j = 1 \}$

Primer $n=3$: $p_0 + p_1 + p_2 = 0$



To je t.i. d-ratnežni simpleks

NPR: število pik pri slučajnem metu G-strave kocke $\binom{12 \dots G}{p_0 \ p_1 \ \dots \ p_G}$

Tu je parametričen prostor 5 razsežen

Med drugim nas zanimata domneva cisto konkretnje porazdelitve: $(p_0, \dots, p_d) = (\pi_0, \dots, \pi_d)$ Za neke fiksne verjetnosti π_0, \dots, π_d

Domneva $H \subset \mathbb{H}$ je "enostavna": to je enoslementna množica

Funkcija verjetja: $L(x; p) = L(x_1, \dots, x_n; p_0, \dots, p_d) = \prod_{j=0}^d p_j^{\pi_j(x)}$, kjer je $\pi_j(x) = \sum_{i=1}^n 1_{\{x_i = \xi_j\}}$ frekvence pojavljanje vrednosti ξ_j v vzorcu.

Sveda je $\pi_0(x) + \dots + \pi_d(x) = n$

Gle za problem maksimizacije z uvozo [izčemo uvezani ekstreem]

$$G(p_0, \dots, p_d, \lambda) = \sum_{j=0}^d \pi_j \ln p_j + \lambda \left(\sum_{j=0}^d p_j - 1 \right)$$

Uvoz / en Lagrangev
množitelj

Ekstremlate? Sedaj lahko odvojimo po vseh p_j in λ

$$\frac{\partial G}{\partial p_j} = \frac{t_j}{p_j} + \lambda$$

$$\frac{\partial G}{\partial \lambda} = \sum_{j=0}^n p_j - 1$$

$$t_j : t_j + \lambda p_j = 0 \quad , \quad \sum_{j=0}^n p_j = 1$$

$$\left\{ \begin{array}{l} \sum_{j=0}^n p_j \\ j=0 \end{array} \right.$$

$$n + \lambda = 0$$

$$\Rightarrow \hat{p}_j = \frac{t_j}{n} \quad , \quad \hat{\lambda} = -n$$

✓ Ta funkcija je Lock-konkavna \rightarrow DN

tekarje se, da gre za maksimum (DN: $\ln(x) : \mathbb{R} \rightarrow \mathbb{R}$ je konkavna)

ker je konkavna, če je opt. v metrajnosti
ni problem, če pa je v rebri te
moramo je dodatno preprizeti

Nastopanje nizelih frekvenc

$$\cdot t_0 = 0 \Rightarrow L(x; p) = p_1^{t_1} p_2^{t_2} \dots p_d^{t_d} \Rightarrow \text{ocitno se lahko zazimo no } p_0 = 0 \quad (\text{saj imamo samo naravnoge funkcije})$$

Torej če imamo takšno 0, se samo omejimo na manjši prostor in spet pridemo na "analogen"
problem

Priuzemimo: CNV je definirana na $\overline{\mathbb{Z}^d}$; zanje velja $\hat{p}_j = \frac{t_j}{n}$

$$\text{Sledi } \lambda(x) = \frac{\prod_{j=0}^n \pi_j^{t_j}}{\prod_{j=0}^n \left(\frac{t_j}{n}\right)^{t_j}} = \prod_{j=0}^n \left(\frac{n \pi_j}{t_j}\right)^{t_j}$$

Preizkus: Domnevo $(p_0, \dots, p_d) = (\pi_0, \dots, \pi_d)$ zavrnemo, če $\lambda(x) < D$. Konstanta je določena z zahtevo velikosti D :

$$P\left(\prod_{j=0}^n \left(\frac{n \pi_j}{t_j}\right)^{t_j} < D\right) \leq \omega \quad \text{če "velja" } (\pi_0, \dots, \pi_d)$$

Tedaj ima vektor (t_0, t_1, \dots, t_d) multinomsko porazdelitev

$$[(t_0, t_1) \sim \text{Bin}]$$

$$P((t_0, \dots, t_d) = (t_0, \dots, t_d)) = \frac{n!}{t_0! t_1! \dots t_d!} \pi_0^{t_0} \pi_1^{t_1} \dots \pi_d^{t_d}$$

multinomialni koeficient

Zadaja verjetnih vrednosti? $\{(t_0, \dots, t_d) \in \mathbb{Z}_+^{d+1} \mid t_0 + \dots + t_d = n\}$

$$\sum_{\substack{(t_0, \dots, t_d) \in \mathbb{Z}_+^{d+1} \\ t_0 + \dots + t_d = n}} \mathbb{1} \left\{ \prod_{j=0}^n \left(\frac{n \pi_j}{t_j}\right)^{t_j} < D \right\} \cdot \frac{n!}{t_0! t_1! \dots t_d!} \pi_0^{t_0} \pi_1^{t_1} \dots \pi_d^{t_d}$$

Kako bi to sprogramirati: for $t_0=0$ to n

for $t_1=0$ to $n-t_0$

for $t_{d-1}=0$ to $n-t_0-\dots-t_{d-2}$

$$\lambda = \prod_{j=0}^d \left(\frac{n\pi_j}{J} \right)^{T_j}$$

Priekusa: $\begin{cases} H \text{ zaurnemo, } \text{če } \lambda \leq D \\ H \text{ ne zaurnemo, } \text{če } \lambda \geq D \end{cases}$

Določilev konstante D je zahteva, da naj bo velikost priekusa $\leq D$, je v praksi lahko numerično zelo intenzivna ali celo neizvedljiva.

Glaanca urlina priekusovanja na podlagi neznanja verjetji je asymptotično obnašanje statistike A.

↪ IZREK (Wilks)

Naj bo Θ gladka mnogoterost razsežnosti d (npr. Θ je \mathbb{R}^d v \mathbb{R}^d , Θ je prostika take gladke preslikave $V: \mathbb{R}^{d+n} \rightarrow \mathbb{R}^n$, katera

Jacobijevka ima v vsaki točki v $V'(\theta)$ poln rang

$$\begin{matrix} v_1 = 0 \\ \vdots \\ v_n = 0 \end{matrix}$$

[Jacobijevka lin. funkcija je kar sama sebi]
Saj jo najbolje gladko? aproksimira

Zgled: $f: \mathbb{R}^{d+n} \rightarrow \mathbb{R}$

$$V(x_0, \dots, x_d) = x_0^2 + \dots + x_d^2 - 1$$

Hilča: $x_0^2 + \dots + x_d^2 - 1 = 0 \rightarrow$ To je sfers.

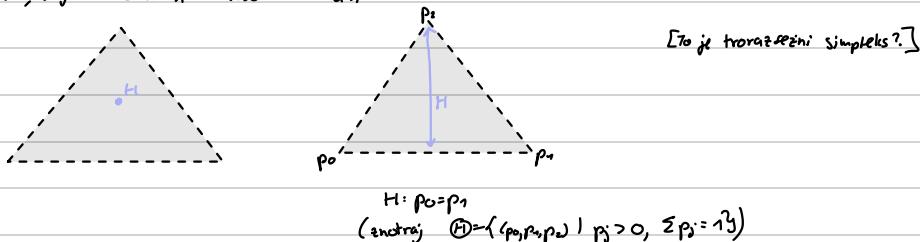


če dodamo je $v_2(f(x_0, \dots, x_d)) = (x_0^2)^2 + x_1^2 + \dots + x_d^2 - 1$
 \hookrightarrow sfers premašljena v prvi spremenljivici

in naj bo $H \subset \Theta$ gladka h-razšrena zaprta prisnočetost (brez robov) v Θ

Naj uveljavijo regularni privzetki na gostote $f(\cdot; \theta)$ iz razdelka o ceniki največjega verjetja

če H drži, velja $-2 \ln \lambda_n \xrightarrow{n \rightarrow \infty} \chi^2_{d-h}$



↪ Na podlagi Wilksnega izreka za "velike" vzorce PRIVZAMEMO $-2 \ln \lambda \sim \chi^2_{d-h}$, če H drži! !

↓ strog paidejica

d percent

če predpostavke izreka držijo za velike vzorce preizkusimo takole:

- ↑ H zaurnemo; če $-2 \ln \lambda > \chi^2_{d-h; d} = F^{-1}_{\chi^2_{d-h}}(1-d)$
- ↓ H ne zaurnemo; sicer

napakos
1. redca

↪ KOMENTAR: Wilksov izrek zagotavlja $\lim_{n \rightarrow \infty} P(-2 \ln \lambda_n > \chi^2_{d-h}; \alpha) = \alpha$, če H drži)

↓ limitna velikost preizkusa je α

$$\begin{aligned} \text{zapisimo } -2\ln\lambda &= -2 \sum_{j=0}^d T_j \ln \left(\frac{n\pi_j}{T_j} \right) \\ -2\ln\lambda &= -2 \sum_{j=0}^d T_j \ln \left(\frac{n\pi_j}{T_j} - 1 + 1 \right) \end{aligned}$$

S pomočjo Taylorjeve formule $\ln(1+\xi) = \xi - \frac{\xi^2}{2} + O(\xi^3)$

po Wilksonovem izrekcu
velja $-2\ln\lambda \rightarrow \chi^2_{d+0}$
če imamo verjetnosti $(\pi_0, \pi_1, \dots, \pi_d)$, tudi
dovnečna drži:

$$-2\ln\lambda \approx -2 \sum_{j=0}^d T_j \cdot \underbrace{\left(\left(\frac{n\pi_j}{T_j} - 1 \right) - \frac{1}{2} \left(\frac{n\pi_j}{T_j} - 1 \right)^2 \right)}$$

$$\sum_{j=0}^d n\pi_j - T_j \\ = n \cdot 1 - n = 0$$

$$= \sum_{j=0}^d \frac{(T_j - n\pi_j)^2}{T_j} \quad \text{: zkorče se (Pearson), da tudi } \sum_{j=0}^d \frac{(T_j - n\pi_j)^2}{T_j} \xrightarrow{\text{D}} \chi^2_{d+0}, \text{ če "velja" } (\pi_0, \pi_1, \dots, \pi_d)$$

Problem bi se lahko pojavil če bi bil $T_j = 0$: za velikosti π_j licno proti π_j , kar nič

$$\prod_{j=0}^d \left(\frac{n\pi_j}{T_j} \right)^{T_j} \quad \text{smo danih iz teorema v imenovanem poglavju bilo}$$

$$\overbrace{\prod_{j=0}^d \left(\frac{n\pi_j}{T_j} \right)^{T_j}}^{\text{Tu je bil rezultat maksimizacije}} \xrightarrow{\text{D}} \chi^2_{d+0} \quad \text{je bi bil tu usaj teks. } = 0, \text{ potem je } j_0 = 1, \text{ torej sploh ne nastopa}$$

v L , torej če bi imeli $T_j = 0$ ga moramo ignorirati ["/zpadle"]

$$\prod_{j=0}^d \left(\frac{n\pi_j}{T_j} \right)^{T_j} \quad \text{To torej } T_j = 0 \text{ ignoriramo}$$

če na odprtih simpleksi

• V PRACI - Če nimamo dandži velikosti usorčen bi lahko bil $T_j = 0$

Pearson je dokazal že da velja tudi:

$$\sum_{j=0}^d \frac{(T_j - n\pi_j)^2}{n\pi_j} \xrightarrow{\text{D}} \chi^2_d$$

standardna
pearsonova
hi-kvadrat
statistika

če je (π_0, \dots, π_d) porazdeljen multinomsko

s parametrom $(\pi_0, \pi_1, \dots, \pi_d)$